# Robust GMM Estimation for Tempered Stable OU Models: A Characteristic-Function Approach

作者姓名
学校名称　学院或系所

2026 年 5 月

**摘要**

针对 Classical Tempered Stable（CTS）Lévy 过程驱动的 Ornstein–Uhlenbeck（OU）模型在重尾和异常观测下估计不稳定的问题，本文研究其稳健 GMM 估计。CTS–OU 模型能够同时刻画均值回复、跳跃、厚尾和尾部指数衰减等特征，适合描述 VIX 等具有非高斯尾部的金融变量。由于该类模型的转移密度通常难以写成简单闭式形式，GMM 为参数估计提供了一条可行路径；但在重尾样本、多矩条件和异常观测并存时，普通 GMM 的动态矩容易受到极端观测影响，组合矩条件的协方差矩阵也可能出现病态，从而导致结构参数估计不稳定。

为缓解上述问题，本文构造了 PC-CF-RGMM 估计方法。该方法结合了三项处理：对低阶动态矩进行 Huber 型有界化，以减弱极端观测的影响；引入标准化特征函数矩，以补充低阶动态矩对尾部信息刻画不足的问题；对组合矩条件协方差矩阵进行主成分正则化，以改善多矩条件下权重矩阵的数值稳定性。

Monte Carlo 模拟表明，在随机污染、块状污染和尾部污染下，PC-CF-RGMM 对尺度参数 $\sigma$ 的估计最为稳定；在块状污染下，对长期均值 $\mu$ 的估计也更稳健。基于 VIX 日度数据的实证结果进一步支持这一结论：真实样本中的矩条件协方差矩阵存在明显病态，稳健方法得到的 $\sigma$ 明显低于普通 GMM，并且在滚动窗口与胖手指型异常冲击检验下表现出更高稳定性。另一方面，三种方法在样本外一步条件均值预测上的差异很小。这说明本文方法的主要价值不在于提高短期预测精度，而在于在异常观测和重尾环境下更稳健地识别模型结构参数。

**关键词：** Classical Tempered Stable Lévy 过程；Ornstein–Uhlenbeck 过程；稳健 GMM；特征函数矩；VIX

**MSC 2020：** 62F35, 62M10, 60G51, 91G70

# 目录

**1 引言** **3**

**2 CTS Lévy 驱动的 OU 模型设定** **5**

**3 融合动态矩与特征函数矩的 GMM 估计框架** **6**
3.1 基于动态矩与特征函数矩的基准 GMM . . . . . 7
3.2 动态矩有界化的 Huber-GMM . . . . . 9
3.3 主成分正则化的 PC-CF-RGMM . . . . . 10
3.4 数值实现与调参设定 . . . . . 11

**4 污染环境下的 Monte Carlo 模拟比较** **15**
4.1 模拟设计与污染机制 . . . . . 16
4.2 代表性估计结果概览 . . . . . 17
4.3 多种污染下尺度参数 $\sigma$ 的稳健性 . . . . . 18
4.4 块状污染下长期均值 $\mu$ 的稳健性 . . . . . 19
4.5 模拟结果小结 . . . . . 20

**5 VIX 波动率指数的稳健 GMM 实证分析** **21**
5.1 VIX 数据特征与 log-CTS-OU 模型设定 . . . . . 21
5.2 全样本结构参数估计与矩协方差诊断 . . . . . 22
5.3 滚动窗口下结构参数的时间稳定性 . . . . . 24
5.4 胖手指（fat-finger）异常冲击下的稳健性检验 . . . . . 25
5.5 一步均值预测的补充检验 . . . . . 27
5.6 实证结果小结 . . . . . 28

**6 结论** **28**

**A CTS-OU 随机积分项的数值抽样方法** **30**

**B Monte Carlo 补充结果与数值优化诊断** **30**
B.1 重点参数的补充统计量 . . . . . 30
B.2 数值优化表现 . . . . . 31

**C VIX 数据诊断与参数稳定性补充图** **32**
C.1 VIX 数据诊断图 . . . . . 33
C.2 滚动窗口核心参数估计路径 . . . . . 33

**参考文献** **37**

# 1 引言

Ornstein–Uhlenbeck（OU）过程是一类经典均值回复模型，在利率、波动率指数、能源价格和价差交易等金融问题中均有广泛应用。若驱动噪声为布朗运动（Brownian motion），则模型具有较好的解析性质，但难以刻画金融数据中普遍存在的尖峰、跳跃和厚尾现象。为克服这一限制，非高斯 Lévy 过程驱动的 OU 型模型受到广泛关注。Barndorff-Nielsen and Shephard (2001) 系统讨论了非高斯 OU 型过程在金融经济学中的应用。Tempered stable 过程通过对稳定过程尾部进行指数削减，在保留跳跃、厚尾和高峰特征的同时获得更好的矩性质，其一般构造和过程性质可参见 Rosiński (2007) 和 Küchler and Tappe (2013)。

本文关注 Classical Tempered Stable（CTS）Lévy 过程驱动的 OU 模型。Tempered stable 过程通过对稳定过程尾部进行指数削减，在保留跳跃、厚尾和高峰特征的同时获得更好的矩性质，其一般构造和过程性质可参见 Rosiński (2007) 和 Küchler and Tappe (2013)。在金融建模中，tempered stable 类过程已被用于刻画资产收益的精细结构和尾部行为 (Carr et al., 2002)，也被进一步扩展到尾部指数衰减随时间变化的情形 (Kim et al., 2022)。本文采用 CTS Lévy 驱动项，是为了在 OU 均值回复结构下同时刻画小跳跃活跃度、厚尾行为以及尾部指数衰减。其参数 $\alpha$ 控制小跳跃活跃度和尾部形状，$\lambda$ 控制尾部指数衰减速度。然而，该类模型的转移密度通常不存在简单闭式表达，使得极大似然估计在实际应用中面临计算困难。

广义矩估计（GMM）由 Hansen (1982) 系统提出，因其不依赖显式似然函数，成为估计转移密度不可得或难以计算模型的重要工具。然而，经典 GMM 在重尾样本和异常观测存在时可能表现不稳定。其原因在于，常用动态矩条件往往包含残差二次项或状态变量乘积项，这类矩函数通常无界。因此，单个极端观测就可能对估计结果产生过大影响。稳健统计中影响函数和有界估计函数的系统理论可参见 Huber and Ronchetti (2009)。在 GMM 框架下，Ronchetti and Trojani (2001) 指出，矩条件函数的有界性与 GMM 估计量及相关检验统计量的局部稳健性密切相关；Dell'Aquila et al. (2003) 则将稳健 GMM 思想用于金融短利率模型，说明稳健矩估计在金融时间序列中的实际意义。

除稳健性问题外，CTS-OU 模型还面临尾部参数识别困难。仅依赖低阶动态矩条件时，$\alpha$ 与 $\lambda$ 对低阶矩的影响可能存在相互补偿，导致有限样本下尾部参数估计不稳定。经验特征函数（empirical characteristic function, ECF）方法为这一问题提供了自然补充。由于特征函数与分布函数一一对应，ECF 矩条件能够利用整个分布的信息，尤其适合处理密度函数难以显式表达但特征函数可得的模型。Feuerverger and McDunnough (1981) 早期讨论了经验特征函数程序的效率问题；Carrasco and Florens (2000) 将 GMM 推广到连续统矩条件，从而为利用一族特征函数矩提供了理论基础。对于时间序列情形，Knight and Yu (2002) 证明了经验特征函数估计量在平稳时间序列中的相合性和渐近正态性。动态模型中的特征函数矩和连续 GMM 估计进一步由 Carrasco et al. (2007) 系统发展。

然而，引入大量特征函数矩条件会带来新的问题：矩条件维度较高时，GMM 权重

矩阵可能接近奇异，进而导致有限样本估计不稳定。对此，正则化思想提供了重要工具。Carrasco (2012) 从多工具变量（many instruments）问题出发，系统讨论了 Tikhonov、Landweber–Fridman、谱截断和主成分等正则化方法；Doran and Schmidt (2006) 也表明，在矩条件较多时，使用权重矩阵主成分可以改善 GMM 的有限样本性质。主成分正则化与连续统特征函数 GMM 中的正则化逆算子类似。它保留协方差矩阵中信息较强、数值较稳定的方向，同时削弱小特征值方向带来的噪声放大。

基于上述讨论，本文在统一的 CTS-OU 设定下比较三种估计方法：基准 GMM、Huber-GMM 和 PC-CF-RGMM。其中，PC-CF-RGMM 指主成分正则化特征函数稳健 GMM（principal-component regularized characteristic-function robust GMM）。三种方法都使用特征函数矩来利用 CTS 扰动项的分布信息，但处理重点并不相同：基准 GMM 直接使用原始动态矩；Huber-GMM 在此基础上对动态矩进行 Huber 型有界化；PC-CF-RGMM 则进一步对权重矩阵实施主成分正则化。

本文的贡献主要体现在以下几个方面：

(1) 在 CTS Lévy 驱动 OU 模型中构造结合 Huber 型稳健动态矩、标准化特征函数矩和主成分正则化权重矩阵的 GMM 估计框架；

(2) 在统一包含特征函数矩条件的设定下，比较基准 GMM、Huber-GMM 和 PC-CF-RGMM，从而分离动态矩稳健化和权重矩阵正则化的作用；

(3) 通过 Monte Carlo 模拟考察随机污染、块状污染和尾部污染下关键结构参数的估计稳定性；

(4) 基于 VIX 日度数据，从全样本估计、矩协方差病态诊断、滚动窗口和胖手指型异常冲击四个角度检验稳健估计方法的实证表现。

本文实证部分以 CBOE VIX 日度数据为例。VIX 通常被视为市场预期波动率和风险情绪的重要指标，Whaley (2000) 将其称为投资者恐惧指标。VIX 具有明显的均值回复、高持续性、厚尾和危机期尖峰特征，是检验非高斯 OU 型模型和稳健估计方法的典型金融序列。关于 VIX 动态及其衍生品定价，早期研究已将均值回复结构用于波动率期货和期权定价 (Grünbichler and Longstaff, 1996)，后续研究进一步表明，多因子或更一般的波动率结构对于刻画 VIX 衍生品价格具有重要作用 (Mencía and Sentana, 2013)。近年来，含有 OU 结构、tempered stable 扰动或更高阶多项式波动率结构的模型也被用于 VIX 期权或 SPX–VIX 联合校准问题 (Yin and Huo, 2022; Abi Jaber et al., 2023)。本文不直接研究 VIX 衍生品定价，而是利用 VIX 现货序列检验 CTS-OU 模型下不同 GMM 估计方法的结构参数稳定性。

本文结构如下。第 2 节介绍模型设定。第 3 节构造 GMM、Huber-GMM 和 PC-CF-RGMM。第 4 节给出数值模拟设计与结果。第 5 节给出 VIX 实证分析。第 6 节总结全文。

# 2 CTS Lévy 驱动的 OU 模型设定

设 $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t\geq 0}, P)$ 为满足通常条件的滤过概率空间。本文考虑如下 Classical Tempered Stable Lévy 过程驱动的 Ornstein–Uhlenbeck 模型：

$$dX_t = -\kappa(X_t - \mu)dt + \sigma dL_t, \qquad \kappa > 0,\ \sigma > 0. \tag{1}$$

其中，$X_t$ 表示连续时间状态变量，$\kappa$ 为均值回复速度，$\mu$ 为长期均值，$\sigma$ 为扰动项的尺度参数，$L_t$ 为对称 Classical Tempered Stable Lévy process。与 Brownian motion 驱动的 OU 模型相比，非高斯 Lévy 驱动的 OU 型模型能够刻画金融时间序列中常见的跳跃、尖峰厚尾和非正态波动特征，这类模型在金融经济学中的应用可参见 Barndorff-Nielsen and Shephard (2001)。

本文采用对称 Classical Tempered Stable Lévy 测度：

$$\nu(dx) = C\frac{e^{-\lambda|x|}}{|x|^{1+\alpha}}dx, \qquad x \neq 0, \tag{2}$$

其中

$$0 < \alpha < 2, \qquad \lambda > 0, \qquad C > 0.$$

参数 $\alpha$ 控制小跳跃活跃度和尾部形状，参数 $\lambda$ 控制尾部指数衰减速度。一般而言，较小的 $\lambda$ 对应更缓慢的尾部衰减，而较大的 $\lambda$ 对应相对轻尾的分布结构。此类 tempered stable 分布和过程的尾部削减机制及其概率性质已由 Rosiński (2007) 和 Küchler and Tappe (2013) 进行系统研究。为减少待估参数维度，本文对 $L_t$ 进行方差标准化，令

$$\mathrm{Var}(L_1) = 1.$$

由对称 CTS Lévy 测度可得

$$\mathrm{Var}(L_1) = 2C\Gamma(2-\alpha)\lambda^{\alpha-2}, \tag{3}$$

因此

$$C(\alpha, \lambda) = \frac{1}{2\Gamma(2-\alpha)\lambda^{\alpha-2}}. \tag{4}$$

在该标准化下，$L_1$ 的特征指数可写为

$$\Psi_L(u; \alpha, \lambda) = C(\alpha, \lambda)\Gamma(-\alpha)\left[(\lambda - iu)^\alpha + (\lambda + iu)^\alpha - 2\lambda^\alpha\right], \tag{5}$$

从而

$$E\left[e^{iuL_1}\right] = \exp\{\Psi_L(u; \alpha, \lambda)\}. \tag{6}$$

式中复数幂采用主值定义。该特征指数刻画了 CTS Lévy 过程的分布结构，也是后文

构造特征函数矩条件的基础。

由于式中模型为线性随机微分方程，对任意时间间隔 $h > 0$，其解可写为

$$X_{t+h} = \mu + e^{-\kappa h}(X_t - \mu) + \sigma \int_t^{t+h} e^{-\kappa(t+h-s)} dL_s. \tag{7}$$

因此，在给定 $X_t$ 的条件下，$X_{t+h}$ 的条件均值为

$$E(X_{t+h} \mid X_t) = \mu + e^{-\kappa h}(X_t - \mu). \tag{8}$$

对应的随机积分扰动项为

$$\eta_{t,h}(\theta) = \sigma \int_t^{t+h} e^{-\kappa(t+h-s)} dL_s. \tag{9}$$

由 Lévy 积分的特征函数性质，$\eta_{t,h}(\theta)$ 的特征函数为

$$\phi_h(u;\theta) = \exp\left\{ \int_0^h \Psi_L\left(u\sigma e^{-\kappa r}; \alpha, \lambda\right) dr \right\}. \tag{10}$$

这表明，虽然 CTS-OU 模型的转移密度通常不存在简单闭式表达，但其随机积分扰动项的特征函数可以由 CTS 特征指数显式表示。因此，本文可以在不直接使用显式似然函数的情况下，通过特征函数矩条件构造 GMM 类估计方法。利用特征函数替代密度函数进行估计的思想与经验特征函数估计文献一致，相关理论基础可参见 Feuerverger and McDunnough (1981)、Knight and Yu (2002) 和 Carrasco et al. (2007)。

本文的待估参数向量为

$$\theta = (\kappa, \mu, \sigma, \alpha, \lambda)'. \tag{11}$$

其中，$\kappa, \mu, \sigma$ 决定 OU 过程的均值回复结构和扰动尺度，$\alpha, \lambda$ 决定 CTS Lévy 驱动项的尾部形状和尾部衰减速度。后文将基于离散观测样本构造不同的 GMM 估计方法，对参数向量 $\theta$ 进行估计。

# 3 融合动态矩与特征函数矩的 GMM 估计框架

广义矩估计的基本思想是：给定参数向量 $\theta$，构造向量值矩函数 $g_j(\theta) \in \mathbb{R}^q$，使其在真实参数 $\theta_0$ 下满足矩条件。该估计框架由 Hansen (1982) 系统提出，并为不依赖显式似然函数的半参数估计提供了统一方法。具体地，本文考虑矩条件

$$E[g_j(\theta_0)] = 0. \tag{12}$$

这里，$g_j(\theta)$ 称为矩函数，$E[g_j(\theta_0)] = 0$ 称为相应的矩条件。给定样本矩均值

$$\bar{g}_n(\theta) = \frac{1}{n}\sum_{j=1}^{n} g_j(\theta), \tag{13}$$

GMM 估计量定义为

$$\hat{\theta} = \arg\min_{\theta\in\Theta} \bar{g}_n(\theta)' W_n \bar{g}_n(\theta), \tag{14}$$

其中，$\Theta$ 为参数空间，$W_n$ 为半正定权重矩阵。

本文在同一 CTS-OU 模型设定下比较三种估计方法：基准 GMM、Huber-GMM 和 PC-CF-RGMM。三种方法使用相同的模型结构和标准化特征函数矩条件，区别在于两个方面：第一，低阶动态矩是否经过 Huber 型有界化处理；第二，第二步 GMM 权重矩阵是否进行主成分正则化。因而，三种方法可以看作在同一组合矩条件框架下逐步增强稳健性和数值稳定性的估计程序。表 1 概括了三种方法的差异。

表 1: 三种估计方法的比较

| 方法 | Huber 有界化 | CF 矩函数 | PC 正则化权重 |
|---|---|---|---|
| GMM | 否 | 是 | 否 |
| Huber-GMM | 是 | 是 | 否 |
| PC-CF-RGMM | 是 | 是 | 是 |

## 3.1 基于动态矩与特征函数矩的基准 GMM

如第 2 节所述，本文估计参数向量 $\theta = (\kappa, \mu, \sigma, \alpha, \lambda)'$。仅依赖低阶动态矩时，$\alpha$ 与 $\lambda$ 对低阶矩的影响可能相互补偿，使尾部参数在有限样本下识别不稳定。由于特征函数能够唯一刻画分布，经验特征函数矩可为密度函数难以显式计算的模型提供额外分布信息，这一点与 Feuerverger and McDunnough (1981)、Knight and Yu (2002) 以及 Carrasco and Florens (2000) 的研究思路一致。为同时利用动态结构信息与 CTS 扰动项的分布信息，基准 GMM 的组合矩函数取为

$$g_j^{\mathrm{GMM}}(\theta) = \begin{pmatrix} d_j(\theta) \\ \rho_{\mathrm{cf}}\, c_j(\theta) \end{pmatrix}, \tag{15}$$

其中 $d_j(\theta)$ 为低阶动态矩函数，$c_j(\theta)$ 为标准化特征函数矩函数，$\rho_{\mathrm{cf}} > 0$ 为平衡两类矩量级的尺度调整参数。为了估计 $\theta = (\kappa, \mu, \sigma, \alpha, \lambda)'$，动态矩 $d_j(\theta)$ 主要利用 OU 过程的均值回复与方差结构，对 $\kappa$、$\mu$ 和 $\sigma$ 的识别较为直接；标准化特征函数矩 $c_j(\theta)$ 则利用 CTS 随机积分扰动项的分布形状信息，为尾部参数 $\alpha$ 和 $\lambda$ 的估计提供补充约束。两类矩条件共同组成基准 GMM 的矩函数。

下面分别介绍式 (15) 中两类矩函数的构造。设离散观测时点为 $t_j = jh$，$j = 0, 1, \ldots, n$，记 $X_j = X_{t_j}$。

**(i) 低阶动态矩函数 $d_j(\theta)$：刻画均值回复与方差结构。** 由连续时间模型的离散转移表示，给定 $X_{j-1}$ 时 $X_j$ 的条件均值为

$$m_j(\kappa,\mu)=\mu+e^{-\kappa h}(X_{j-1}-\mu), \tag{16}$$

据此定义一步预测残差

$$\delta_j(\theta)=X_j-m_j(\kappa,\mu)=X_j-\mu-e^{-\kappa h}(X_{j-1}-\mu). \tag{17}$$

由于 $L_t$ 已标准化为 $\mathrm{Var}(L_1)=1$，随机积分扰动项的理论方差为

$$v_h(\kappa,\sigma)=\sigma^2\frac{1-e^{-2\kappa h}}{2\kappa}, \tag{18}$$

对应的标准化残差为

$$z_j(\theta)=\delta_j(\theta)/\sqrt{v_h(\kappa,\sigma)}. \tag{19}$$

据此构造低阶动态矩函数

$$d_j(\theta)=\begin{pmatrix} z_j(\theta)\\ z_j(\theta)\,\widetilde{X}_{j-1}(\theta)\\ z_j^2(\theta)-1\\ \{z_j^2(\theta)-1\}\,\widetilde{X}_{j-1}(\theta)\end{pmatrix},\qquad \widetilde{X}_{j-1}(\theta)=\frac{X_{j-1}-\mu}{s_X(\theta)},\ s_X(\theta)=\frac{\sigma}{\sqrt{2\kappa}}. \tag{20}$$

其中，前两个分量刻画条件均值结构，主要用于识别 $\kappa$ 和 $\mu$；后两个分量刻画条件方差结构，主要用于识别 $\sigma$。由于低阶矩对尾部形状的刻画有限，单独使用 $d_j(\theta)$ 难以稳定识别 $\alpha$ 和 $\lambda$。

**(ii) 标准化特征函数矩函数 $c_j(\theta)$：补充尾部分布信息。** 低阶动态矩对尾部形状的识别有限，因此进一步引入标准化特征函数矩条件。取有限频率集合 $\mathcal{U}=\{u_1,\dots,u_K\}$。由标准化残差的定义，其理论特征函数为

$$\phi_z(u;\theta)=\phi_h\Big(u/\sqrt{v_h(\kappa,\sigma)};\theta\Big)=\exp\left\{\int_0^h\Psi_L\left(\frac{u\,e^{-\kappa r}}{\sqrt{(1-e^{-2\kappa h})/(2\kappa)}};\alpha,\lambda\right)dr\right\}. \tag{21}$$

对每个 $u_k\in\mathcal{U}$，模型矩条件为 $\mathrm{E}\big[e^{iu_kz_j(\theta_0)}-\phi_z(u_k;\theta_0)\big]=0$，将其实部和虚部分开堆叠，得到

$$c_{j,k}(\theta)=\begin{pmatrix}\cos\{u_kz_j(\theta)\}-\mathrm{Re}\{\phi_z(u_k;\theta)\}\\ \sin\{u_kz_j(\theta)\}-\mathrm{Im}\{\phi_z(u_k;\theta)\}\end{pmatrix},\qquad c_j(\theta)=\big(c_{j,1}(\theta)',\dots,c_{j,K}(\theta)'\big)'. \tag{22}$$

$\phi_z(u;\theta)$ 的形式由 CTS 特征指数 $\Psi_L(\cdot;\alpha,\lambda)$ 决定，因此 $c_j(\theta)$ 携带的是扰动项的分布形状信息，尤其是由 $\alpha$ 和 $\lambda$ 控制的尾部结构。相对于低阶动态矩，CF 矩对尾部参数 $(\alpha,\lambda)$ 更为敏感。同时，正余弦函数有界，有限频率集合下的 CF 矩函数对极端观测的响应天然受到约束。

**(iii) 基准 GMM 估计量。** 组合后的样本矩均值为

$$\bar{g}_n^{\mathrm{GMM}}(\theta) = \frac{1}{n}\sum_{j=1}^{n} g_j^{\mathrm{GMM}}(\theta), \tag{23}$$

基准 GMM 估计量定义为

$$\hat{\theta}_{\mathrm{GMM}} = \arg\min_{\theta\in\Theta} \bar{g}_n^{\mathrm{GMM}}(\theta)' W_n \bar{g}_n^{\mathrm{GMM}}(\theta). \tag{24}$$

基准 GMM 直接使用原始动态矩与标准化特征函数矩，用于估计 $\theta = (\kappa,\mu,\sigma,\alpha,\lambda)'$。该方法未对动态矩做有界化处理，也未对权重矩阵做正则化处理；3.2 与 3.3 节将在此基础上分别引入 Huber 型有界化和主成分正则化。

## 3.2 动态矩有界化的 Huber-GMM

基准 GMM 中的动态矩函数 $d_j(\theta)$ 包含残差平方项以及与滞后状态变量的乘积项，因而在极端观测下可能取值很大。稳健统计中的 Huber 型有界化思想可用于限制异常观测对估计方程的影响 (Huber and Ronchetti, 2009)；在 GMM 框架下，矩函数有界性与估计量及检验统计量的局部稳健性密切相关 (Ronchetti and Trojani, 2001)。因此，为降低异常观测对估计方程的影响，Huber-GMM 对动态矩部分进行 Huber 型有界化，同时保留标准化特征函数矩。

对任意向量 $y\in\mathbb{R}^q$，定义径向 Huber 变换

$$\psi_c(y) = y\min\left\{1, \frac{c}{\|y\|}\right\}, \qquad c>0, \tag{25}$$

并约定 $\psi_c(0)=0$。当 $\|y\|\le c$ 时，$\psi_c(y)=y$；当 $\|y\|>c$ 时，$\psi_c(y)$ 将 $y$ 压缩到半径为 $c$ 的球面上。

为平衡不同动态矩分量的量纲，先用尺度矩阵 $A_n$ 对 $d_j(\theta)$ 标准化，并定义

$$d_{j,c}(\theta) = \psi_c\{A_n d_j(\theta)\}. \tag{26}$$

其中，$A_n$ 为动态矩各分量的尺度矩阵，具体构造见第 3.4 小节。由于特征函数矩由正弦和余弦函数构成，本身有界，本文不再对 $c_j(\theta)$ 作额外 Huber 变换。

Huber-GMM 的组合矩函数为

$$g_j^{\text{Huber}}(\theta) = \begin{pmatrix} d_{j,c}(\theta) \\ \rho_{\text{cf}} c_j(\theta) \end{pmatrix}. \tag{27}$$

相应的样本矩均值为

$$\bar{g}_n^{\text{Huber}}(\theta) = \frac{1}{n}\sum_{j=1}^{n} g_j^{\text{Huber}}(\theta), \tag{28}$$

估计量定义为

$$\hat{\theta}_{\text{Huber}} = \arg\min_{\theta\in\Theta} \bar{g}_n^{\text{Huber}}(\theta)' W_n \bar{g}_n^{\text{Huber}}(\theta). \tag{29}$$

与基准 GMM 相比，Huber-GMM 的唯一变化是将原始动态矩 $d_j(\theta)$ 替换为有界化后的 $d_{j,c}(\theta)$。类似的稳健 GMM 思路已被用于金融短利率过程估计，说明该类方法在含有异常观测和模型近似误差的金融时间序列中具有实际意义 (Dell'Aquila et al., 2003)。类似的稳健 GMM 思路已被用于金融短利率过程估计，说明该类方法在含有异常观测和模型近似误差的金融时间序列中具有实际意义 (Dell'Aquila et al., 2003)。

## 3.3 主成分正则化的 PC-CF-RGMM

PC-CF-RGMM 在 Huber-GMM 的组合矩函数基础上，进一步对 GMM 权重矩阵进行主成分正则化。该处理与多矩条件或多工具变量 GMM 中的正则化思想一致：当矩条件维度较高时，直接反演样本协方差矩阵可能放大小特征值方向的有限样本噪声，而主成分或谱截断方法可以改善权重矩阵的数值稳定性 (Doran and Schmidt, 2006; Carrasco, 2012)。该方法使用的组合矩函数为

$$g_j^{\text{PC}}(\theta) = \begin{pmatrix} d_{j,c}(\theta) \\ \rho_{\text{cf}} c_j(\theta) \end{pmatrix}. \tag{30}$$

其中，$d_{j,c}(\theta)$ 为 Huber 型动态矩函数，$c_j(\theta)$ 为标准化特征函数矩函数。记其样本矩均值为

$$\bar{g}_n^{\text{PC}}(\theta) = \frac{1}{n}\sum_{j=1}^{n} g_j^{\text{PC}}(\theta). \tag{31}$$

PC-CF-RGMM 采用两步估计。第一步使用初始权重矩阵得到初步估计量 $\widetilde{\theta}$。在 $\widetilde{\theta}$ 处计算组合矩函数的样本协方差矩阵：

$$\widehat{S}_n = \frac{1}{n}\sum_{j=1}^{n} \left[g_j^{\text{PC}}(\widetilde{\theta}) - \bar{g}_n^{\text{PC}}(\widetilde{\theta})\right] \left[g_j^{\text{PC}}(\widetilde{\theta}) - \bar{g}_n^{\text{PC}}(\widetilde{\theta})\right]'. \tag{32}$$

对 $\widehat{S}_n$ 作特征值分解：

$$\widehat{S}_n = \widehat{P}\widehat{\Lambda}\widehat{P}', \qquad \widehat{\Lambda} = \mathrm{diag}(\widehat{\lambda}_1, \ldots, \widehat{\lambda}_q), \tag{33}$$

其中

$$\widehat{\lambda}_1 \geq \widehat{\lambda}_2 \geq \cdots \geq \widehat{\lambda}_q \geq 0.$$

给定累计解释比例阈值 $\tau \in (0,1)$，选择最小整数 $r$，使得

$$\frac{\sum_{\ell=1}^{r} \widehat{\lambda}_\ell}{\sum_{\ell=1}^{q} \widehat{\lambda}_\ell} \geq \tau. \tag{34}$$

记前 $r$ 个特征向量组成的矩阵为

$$\widehat{P}_r = (\widehat{p}_1, \ldots, \widehat{p}_r), \qquad \widehat{\Lambda}_r = \mathrm{diag}(\widehat{\lambda}_1, \ldots, \widehat{\lambda}_r). \tag{35}$$

主成分正则化权重矩阵定义为

$$\widehat{W}_{\mathrm{PC}} = \widehat{P}_r \widehat{\Lambda}_r^{-1} \widehat{P}_r'. \tag{36}$$

该权重矩阵只在样本协方差矩阵的主要特征方向上进行反演，从而削弱小特征值方向带来的数值不稳定性。这一思想与 Doran and Schmidt (2006) 使用权重矩阵主成分改善 GMM 有限样本性质的做法一致，也与 Carrasco (2012) 关于病态 GMM 反问题的正则化处理相呼应。

在此基础上，PC-CF-RGMM 的第二步估计量定义为

$$\hat{\theta}_{\mathrm{PC}} = \arg\min_{\theta \in \Theta} \bar{g}_n^{\mathrm{PC}}(\theta)' \widehat{W}_{\mathrm{PC}} \bar{g}_n^{\mathrm{PC}}(\theta). \tag{37}$$

因此，PC-CF-RGMM 与 Huber-GMM 使用相同的组合矩函数，二者的区别在于权重矩阵的构造方式：Huber-GMM 采用通常的 GMM 权重矩阵，而 PC-CF-RGMM 采用基于样本矩协方差矩阵主成分分解的正则化权重矩阵。与基准 GMM 相比，PC-CF-RGMM 同时结合了动态矩函数的 Huber 型有界化和权重矩阵的主成分正则化。上述构造给出了 PC-CF-RGMM 的理论形式。实际估计中，频率集合、Huber 截断常数和主成分保留阈值等调参设定如下。

## 3.4 数值实现与调参设定

本小节说明三种估计方法在数值实现中的具体设定。前文已经给出了 GMM、Huber-GMM 和 PC-CF-RGMM 的一般形式，但在有限样本估计中，仍需明确特征函数频率集合、Huber 截断常数、动态矩尺度化方式、主成分保留准则、参数约束区间以及两步估计程序。本文第 4 节和第 5 节中的所有数值结果均基于本小节的设定。

**矩条件维数。** 本文的组合矩条件由两部分构成。第一部分是 4 维低阶动态矩 $d_j(\theta)$；第二部分是标准化特征函数矩 $c_j(\theta)$。对每一个特征函数频率 $u_k$，本文分别使用其实部和虚部矩条件，因此若频率个数为 $K$，则特征函数矩的维数为 $2K$。本文取 $K = 9$，所以组合矩条件总维数为

$$q = 4 + 2K = 4 + 2 \times 9 = 22. \tag{38}$$

这也是后文实证部分矩条件协方差矩阵诊断中“矩条件维数为 22”的来源。三种估计方法均使用相同的 22 维组合矩条件，以保证比较具有一致基础。

**特征函数频率集合。** 特征函数矩使用标准化残差 $z_j(\theta)$ 构造，因此频率集合也定义在标准化尺度上。本文取

$$\mathcal{U} = \{0.15,\ 0.30,\ 0.50,\ 0.75,\ 1.00,\ 1.35,\ 1.75,\ 2.25,\ 3.00\}. \tag{39}$$

该频率集合覆盖低频、中频和相对高频区域。低频部分主要反映分布在原点附近的曲率信息，与方差和尺度参数识别有关；中高频部分对分布形状和尾部衰减更敏感，有助于识别 CTS 扰动项中的尾部参数 $\alpha$ 和 $\lambda$。这种通过有限频率集合近似利用分布信息的做法，与经验特征函数估计和连续统矩条件 GMM 文献中的基本思想一致 (Feuerverger and McDunnough, 1981; Carrasco and Florens, 2000; Knight and Yu, 2002)。由于标准化残差的特征函数在较高频率处衰减明显，继续增加过高频率往往带来更多有限样本噪声，并加重权重矩阵病态问题。因此，本文使用 $K = 9$ 个频率，在尾部信息利用和数值稳定性之间进行折中。

在组合矩中，特征函数矩前乘尺度系数 $\rho_{\mathrm{cf}}$：

$$g_j(\theta) = \begin{pmatrix} d_j(\theta) \\ \rho_{\mathrm{cf}} c_j(\theta) \end{pmatrix}. \tag{40}$$

基准设定取

$$\rho_{\mathrm{cf}} = 1. \tag{41}$$

这是因为动态矩经过尺度化后通常为 $O(1)$ 量级，而特征函数矩由正弦、余弦函数及理论特征函数差值构成，本身也是有界的。因而在主设定中不再额外降低或放大 CF 矩的权重。

**Huber 有界化与动态矩尺度化。** Huber-GMM 和 PC-CF-RGMM 均对动态矩部分进行有界化处理。为避免不同动态矩分量的量纲差异影响径向 Huber 变换，本文先对 $d_j(\theta)$ 的各个分量进行尺度化。具体地，采用 MAD 尺度构造

$$A_n = \mathrm{diag}\left\{ \frac{1}{1.4826\,\widehat{\mathrm{MAD}}_1}, \ldots, \frac{1}{1.4826\,\widehat{\mathrm{MAD}}_4} \right\}, \tag{42}$$

其中

$$\widehat{\mathrm{MAD}}_\ell = \mathrm{median}_{1\le j\le n}\left|d_{j,\ell}(\theta) - \mathrm{median}_{1\le j\le n}\, d_{j,\ell}(\theta)\right|, \qquad \ell = 1,\dots,4. \tag{43}$$

常数 1.4826 使 MAD 在正态情形下与标准差具有相同尺度。本文使用 MAD 而非样本标准差，是因为样本标准差本身容易受到异常观测影响；若用其对动态矩进行标准化，可能削弱后续 Huber 有界化的作用。需要说明的是，MAD 仅用于估计尺度矩阵 $A_n$，并不对动态矩作中心化调整，从而避免引入依赖样本的中心化项而改变原始矩条件。

在尺度化后，本文对 $A_n d_j(\theta)$ 施加径向 Huber 变换：

$$d_{j,c}(\theta) = \psi_c\{A_n d_j(\theta)\}, \qquad \psi_c(y) = y\min\left\{1, \frac{c}{\|y\|}\right\}. \tag{44}$$

Huber 截断常数取

$$c = 2.5. \tag{45}$$

该取值使正常范围内的动态矩基本保持不变，仅对范数异常偏大的观测行进行收缩。由于特征函数矩由正弦和余弦函数构成，本身有界，本文不再对 $c_j(\theta)$ 施加额外 Huber 变换。

**主成分正则化参数。** PC-CF-RGMM 在第二步估计中对组合矩协方差矩阵进行主成分正则化。设第一步估计为 $\widetilde{\theta}$，在该点计算

$$\widehat{S}_n = \frac{1}{n}\sum_{j=1}^{n}\left[g_j(\widetilde{\theta}) - \bar{g}_n(\widetilde{\theta})\right]\left[g_j(\widetilde{\theta}) - \bar{g}_n(\widetilde{\theta})\right]'. \tag{46}$$

令 $\widehat{\lambda}_1 \ge \cdots \ge \widehat{\lambda}_q$ 为 $\widehat{S}_n$ 的特征值。本文选择最小整数 $r$，使得

$$\frac{\sum_{\ell=1}^{r}\widehat{\lambda}_\ell}{\sum_{\ell=1}^{q}\widehat{\lambda}_\ell} \ge \tau, \qquad \tau = 0.90. \tag{47}$$

即保留能够解释 90% 矩协方差变异的主成分方向。该设定保留了信息较强的主方向，同时避免直接反演小特征值方向，降低有限样本噪声被放大的风险。类似的主成分降维和正则化思想已被用于改善多矩条件 GMM 的有限样本表现 (Doran and Schmidt, 2006; Carrasco, 2012)。后文 VIX 实证中报告的 PC 秩，即根据这一规则得到。

为了进一步提高数值稳定性，本文在构造权重矩阵时还采用以下处理。首先，在矩协方差矩阵中加入岭项：

$$\widehat{S}_n^{\mathrm{ridge}} = \widehat{S}_n + 10^{-4} I_q. \tag{48}$$

其次，对保留的特征值设置下限：

$$\widehat{\lambda}_\ell \leftarrow \max\{\widehat{\lambda}_\ell,\, 10^{-3}\widehat{\lambda}_{\max}\}, \tag{49}$$

并将逆特征值上限设为 200，以避免极小特征值对应方向被过度放大。最后，将 PC 权重矩阵向单位矩阵收缩：

$$\widehat{W} = 0.70\,\widehat{W}_{\mathrm{PC}} + 0.30\,I_q. \tag{50}$$

上述处理并不改变 PC 正则化的基本思想，而是为了在有限样本和多矩条件下获得更稳定的权重矩阵。

**参数空间与边界处理。** 估计在如下紧参数空间内进行：

$$\Theta = [0.005, 0.50] \times [1, 80] \times [0.10, 5.00] \times [0.20, 1.80] \times [0.20, 10.00], \tag{51}$$

分别对应

$$\kappa, \quad \mu, \quad \sigma, \quad \alpha, \quad \lambda.$$

由于 CTS 特征指数中含有 $\Gamma(-\alpha)$，在 $\alpha = 1$ 附近存在数值不稳定，因此本文额外排除

$$|\alpha - 1| < 0.015 \tag{52}$$

的参数取值。优化过程中还对过于接近参数边界和过于接近 $\alpha = 1$ 的候选值加入光滑惩罚项，以减少人为边界解。模拟结果统计时，若估计值距离任一参数区间边界小于该区间长度的 1%，则将其标记为边界解，并从有效成功样本中剔除。

**两步估计程序。** 三种方法的第一步均使用单位权重矩阵：

$$W_n^{(1)} = I_q. \tag{53}$$

对于 GMM 和 Huber-GMM，第一步估计即作为最终估计结果。对于 PC-CF-RGMM，第一步估计仅作为初步估计 $\widetilde{\theta}$，随后在 $\widetilde{\theta}$ 处计算组合矩协方差矩阵，并根据上述主成分规则构造第二步权重矩阵 $\widehat{W}$，再求解

$$\widehat{\theta}_{\mathrm{PC}} = \arg\min_{\theta \in \Theta} \bar{g}_n(\theta)' \widehat{W} \bar{g}_n(\theta). \tag{54}$$

因此，PC-CF-RGMM 与 Huber-GMM 的矩函数相同，区别仅在于第二步使用了 PC 正则化权重矩阵。该设计有助于区分“动态矩稳健化”和“权重矩阵正则化”两类处理的作用。

**优化算法与初始值。** 所有优化均采用 L-BFGS-B 算法，并施加上述参数区间约束。最大迭代次数设为 800，目标函数收敛容差设为 $10^{-9}$。为减轻非凸目标函数下初始值选择的影响，每次估计使用多组初值。首先，通过离散 AR(1) 回归得到 $\kappa$、$\mu$ 和 $\sigma$ 的数

据驱动初值；其次，为尾部参数设置如下网格：

$$(\alpha,\lambda)\in\{(0.45,0.60),(0.60,0.80),(0.75,1.20),(0.75,2.00),(1.20,3.00),(1.30,4.00)\}. \tag{55}$$

该网格覆盖重尾、基准和轻尾情形。最后，再加入若干扰动初值，以增强优化的稳定性。本文每次估计共使用 12 组初值，并选取目标函数值最小的局部解作为最终结果。

表 2 汇总了本文使用的主要数值设定。

表 2: 估计方法的主要数值设定

| 设定 | 符号 | 取值 |
|---|---|---|
| 观测间隔 | $h$ | 1 |
| CF 频率集合 | $\mathcal{U}$ | $\{0.15,0.30,0.50,0.75,1.00,1.35,1.75,2.25,3.00\}$ |
| CF 频率个数 | $K$ | 9 |
| 动态矩维数 | $\dim d_j$ | 4 |
| 组合矩条件维数 | $q=4+2K$ | 22 |
| CF 权重系数 | $\rho_{\mathrm{cf}}$ | 1.0 |
| Huber 截断常数 | $c$ | 2.5 |
| 动态矩尺度 | $A_n$ | MAD 尺度 |
| PC 累计解释比例 | $\tau$ | 0.90 |
| 协方差岭参数 | – | $10^{-4}$ |
| 特征值下限 | – | $10^{-3}\widehat{\lambda}_{\max}$ |
| 逆特征值上限 | – | 200 |
| 权重矩阵收缩 | – | $0.70\widehat{W}_{\mathrm{PC}}+0.30I_q$ |
| $\kappa$ 约束区间 | – | $[0.005,0.50]$ |
| $\mu$ 约束区间 | – | $[1,80]$ |
| $\sigma$ 约束区间 | – | $[0.10,5.00]$ |
| $\alpha$ 约束区间 | – | $[0.20,1.80]$，且 $\lvert\alpha-1\rvert\geq 0.015$ |
| $\lambda$ 约束区间 | – | $[0.20,10.00]$ |
| 第一步权重矩阵 | $W_n^{(1)}$ | $I_q$ |
| 优化算法 | – | L-BFGS-B |
| 最大迭代次数 | – | 800 |
| 收敛容差 | – | $10^{-9}$ |
| 初值个数 | – | 12 |

# 4 污染环境下的 Monte Carlo 模拟比较

本节通过 Monte Carlo 实验比较 GMM、Huber-GMM 和 PC-CF-RGMM 在 CTS-OU 模型中的有限样本表现，重点考察当样本受到随机异常观测、尾部放大和连续块状冲击影响时，稳健化动态矩条件与主成分正则化权重矩阵能否提高结构参数估计的稳定性。

CTS-OU 模型包含均值回复参数、尺度参数和尾部形状参数，不同参数对污染的敏感性并不相同。Huber 有界化主要作用于低阶动态矩中的极端残差和状态变量乘积

项，PC 正则化则主要缓解组合矩条件协方差矩阵病态带来的权重不稳定。因此，稳健化处理并不意味着所有参数在所有场景下都会同时改进。基于这一点，正文重点报告受污染影响最明显、机制解释最清楚的尺度参数 $\sigma$，以及块状污染下的长期均值参数 $\mu$；其余参数的补充统计量放在附录中报告。

## 4.1 模拟设计与污染机制

本文考虑 CTS Lévy 驱动的 OU 过程

$$dX_t = -\kappa(X_t - \mu)\,dt + \sigma\,dL_t, \qquad \kappa > 0, \quad \sigma > 0, \tag{56}$$

其中 $L_t$ 为标准化对称 Classical Tempered Stable Lévy 过程。离散观测间隔取 $h = 1$，相应离散形式为

$$X_j = \mu + e^{-\kappa h}(X_{j-1} - \mu) + \eta_j, \qquad j = 1, \ldots, n, \tag{57}$$

其中

$$\eta_j = \sigma \int_{t_{j-1}}^{t_j} e^{-\kappa(t_j - s)}\,dL_s. \tag{58}$$

本文不直接模拟连续时间 CTS Lévy 路径，而是利用 OU 随机积分项 $\eta_j$ 的理论特征函数进行数值抽样。由于许多 Lévy 驱动模型的特征函数比转移密度更容易获得，基于特征函数反演或精确模拟的数值方法在 tempered stable 及相关 OU 型模型中具有重要作用 (Gil-Pelaez, 1951; Kawai and Masuda, 2012; Grabchak and Sabino, 2020)。具体地，先由

$$\phi_h(u;\theta) = \exp\left\{\int_0^h \Psi_L\big(u\sigma e^{-\kappa r};\alpha,\lambda\big)\,dr\right\}$$

计算创新项特征函数，再通过数值反演得到其分布函数并进行反函数抽样。数值反演和抽样实现细节见附录 A。随后按照表 4 所述机制在增量层面施加污染。该设计用于检验矩函数有界化和权重矩阵正则化在局部异常、连续冲击和尾部放大情形下的稳健性，其动机与稳健 GMM 文献中关于异常观测影响的讨论一致 (Ronchetti and Trojani, 2001; Dell'Aquila et al., 2003)。

样本长度取 $n = 1000$，每种参数场景和污染机制下重复 $R = 100$ 次。为考察尾部厚度与均值回复速度对估计结果的影响，本文设置四组参数场景，见表 3。

表 3: Monte Carlo 参数场景

| 场景 | $\kappa$ | $\mu$ | $\sigma$ | $\alpha$ | $\lambda$ | 说明 |
|---|---|---|---|---|---|---|
| $S_1$ | 0.05 | 20.00 | 1.00 | 0.75 | 2.00 | 基准情形 |
| $S_2$ | 0.05 | 20.00 | 1.00 | 0.60 | 0.80 | 重尾情形 |
| $S_3$ | 0.05 | 20.00 | 1.00 | 1.30 | 4.00 | 轻尾情形 |
| $S_4$ | 0.15 | 20.00 | 1.00 | 0.75 | 2.00 | 快速均值回复 |

为了检验稳健性，本文在无污染路径的增量上加入异常扰动。设

$$\Delta X_j^0 = X_j^0 - X_{j-1}^0 \tag{59}$$

为无污染增量，污染后增量定义为

$$\Delta X_j = \Delta X_j^0 + \xi_j, \tag{60}$$

并由累积增量重构污染路径。污染机制见表 4。

表 4: 污染机制设定

| 污染情形 | 类型 | $\varepsilon$ | $b$ | 说明 |
|---|---|---|---|---|
| $C_0$ | 无污染 | 0.00 | 0.00 | 无污染 |
| $C_1$ | 随机 | 0.01 | 8.00 | 1% 随机污染 |
| $C_2$ | 随机 | 0.03 | 8.00 | 3% 随机污染 |
| $C_3$ | 块状 | 0.03 | 8.00 | 长度为 30 的块状污染 |
| $C_4$ | 尾部 | 0.03 | 8.00 | 3% 尾部污染 |

其中，$b = 8$ 表示污染幅度为无污染增量样本标准差的 8 倍。随机污染模拟离散异常报价，块状污染模拟连续市场冲击，尾部污染模拟极端样本日进一步放大的情形。

对任一参数分量 $\theta_\ell$，本文主要使用 RMSE 衡量估计误差：

$$\mathrm{RMSE}(\widehat{\theta}_\ell) = \left[ \frac{1}{R_s} \sum_{r \in \mathcal{S}} \left( \widehat{\theta}_\ell^{(r)} - \theta_{\ell,0} \right)^2 \right]^{1/2}, \tag{61}$$

其中 $\mathcal{S}$ 表示成功收敛且未被判定为边界解的重复实验集合，$R_s = |\mathcal{S}|$。

## 4.2 代表性估计结果概览

为展示估计结果与真实参数之间的偏离程度，表 5 报告代表性污染情形下核心参数的真值与估计均值。该表主要用于给出后续 RMSE 分析的直观背景：尺度参数 $\sigma$ 直接受到异常增量影响，而连续块状污染还会改变样本路径的局部水平，从而影响长期均值 $\mu$。

表 5: 代表性情形下核心参数的真值与估计均值

| 参数 | 场景 | 污染 | 真值 | GMM | Huber-GMM | PC-CF-RGMM |
|---|---|---|---|---|---|---|
| $\sigma$ | $S_1$ | $C_0$ | 1.000 | 1.004 | 0.836 | 0.843 |
| $\sigma$ | $S_1$ | $C_2$ | 1.000 | 2.112 | 0.921 | 0.909 |
| $\sigma$ | $S_1$ | $C_3$ | 1.000 | 4.869 | 1.818 | 1.652 |
| $\sigma$ | $S_1$ | $C_4$ | 1.000 | 2.163 | 0.859 | 0.853 |
| $\sigma$ | $S_2$ | $C_3$ | 1.000 | 4.869 | 1.608 | 1.308 |
| $\sigma$ | $S_3$ | $C_3$ | 1.000 | 4.869 | 1.776 | 1.484 |
| $\sigma$ | $S_4$ | $C_3$ | 1.000 | 4.869 | 1.349 | 1.425 |
| $\mu$ | $S_1$ | $C_3$ | 20.000 | 31.736 | 26.711 | 23.932 |
| $\mu$ | $S_2$ | $C_3$ | 20.000 | 40.637 | 28.437 | 23.917 |
| $\mu$ | $S_3$ | $C_3$ | 20.000 | 36.622 | 26.328 | 25.753 |
| $\mu$ | $S_4$ | $C_3$ | 20.000 | 35.549 | 25.130 | 20.846 |

表 5 显示，在无污染情形 $C_0$ 下，普通 GMM 对 $\sigma$ 的估计均值接近真实值；但在随机污染、块状污染和尾部污染下，GMM 的 $\sigma$ 估计明显偏离真值。尤其在块状污染 $C_3$ 下，四个参数场景中的 GMM 估计均值均接近 4.869，说明异常增量被明显吸收到尺度参数中。相比之下，Huber-GMM 和 PC-CF-RGMM 的 $\sigma$ 估计更接近真实值 1。

对于长期均值 $\mu$，块状污染下普通 GMM 的估计均值明显高于真实值 20，而 PC-CF-RGMM 的偏离程度相对较小。总体来看，表 5 初步表明，稳健化动态矩和主成分正则化主要改善了污染样本下关键结构参数的估计稳定性。下面进一步从 RMSE 角度分别考察 $\sigma$ 和块状污染下 $\mu$ 的表现。

## 4.3 多种污染下尺度参数 $\sigma$ 的稳健性

尺度参数 $\sigma$ 是模拟中差异最稳定、机制也最清楚的比较对象。前文表 5 已经显示，在污染样本中，普通 GMM 的 $\sigma$ 估计均值容易明显高于真实值，而两种稳健方法的偏离程度相对较小。为了进一步从整体误差角度比较三种方法，图 1 给出不同参数场景和污染机制下 $\sigma$ 的 RMSE。

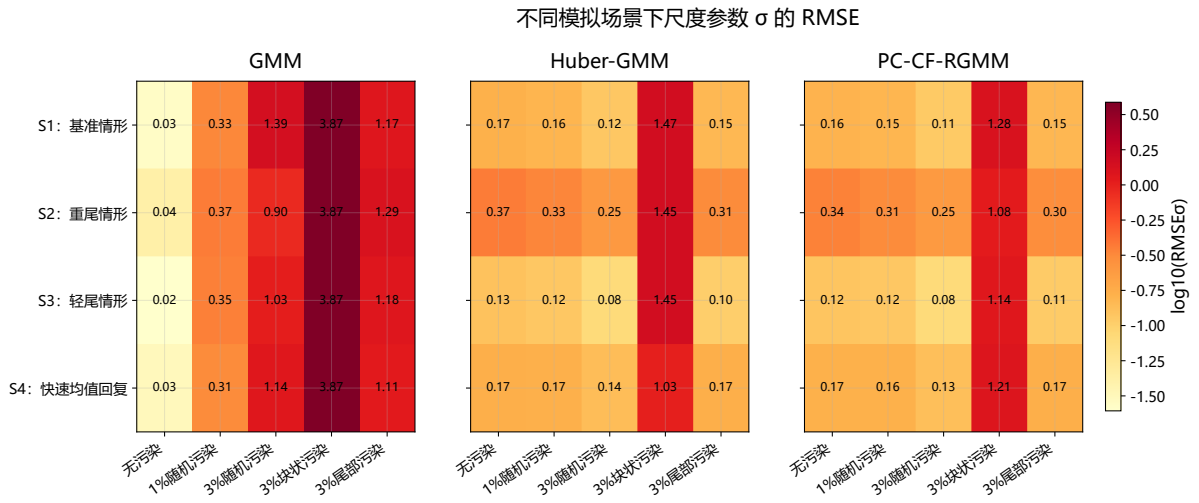



图 1: 不同模拟场景下尺度参数 $\sigma$ 的 RMSE

图 1 表明，一旦样本受到污染，普通 GMM 的尺度参数误差会迅速放大，而 Huber-GMM 和 PC-CF-RGMM 的误差明显较小。以 3% 随机污染为例，四个参数场景下 GMM 的 $\sigma$ RMSE 分别为 1.394、0.904、1.033 和 1.145，而 PC-CF-RGMM 分别降至 0.113、0.246、0.081 和 0.133。块状污染下差异更为明显：GMM 的 $\sigma$ RMSE 在四个场景中几乎都接近 3.87，这与表 5 中 GMM 的 $\sigma$ 估计均值接近 4.869 相对应，说明块状异常增量被明显吸收到尺度参数中。相比之下，PC-CF-RGMM 的 RMSE 约为 1.08–1.28，Huber-GMM 约为 1.03–1.47。尾部污染下，稳健方法同样明显低于 GMM。

这一结果说明，未稳健化 GMM 容易把异常增量解释为扰动尺度本身的上升，从而导致 $\sigma$ 明显高估。由于低阶动态矩中包含残差平方项，少量极端增量就可能显著改变方差类矩条件。Huber 有界化通过压缩极端动态矩的取值，直接减弱了这种放大效应，这与稳健统计和稳健 GMM 中通过有界估计函数降低异常观测影响的思想一致 (Huber and Ronchetti, 2009; Ronchetti and Trojani, 2001)；PC-CF-RGMM 在此基础上进一步削弱小特征值权重方向带来的噪声放大，其正则化动机与多矩条件 GMM 中的主成分和谱截断处理相一致 (Doran and Schmidt, 2006; Carrasco, 2012)。因此，在随机污染、块状污染和尾部污染下，PC-CF-RGMM 都能保持相对稳定的尺度参数识别。结合表 5 的估计均值对照可以看到，PC-CF-RGMM 的改进不仅体现在 RMSE 数值下降上，也体现在污染样本中对真实尺度参数的偏离程度更小。

## 4.4 块状污染下长期均值 $\mu$ 的稳健性

除了尺度参数外，长期均值参数 $\mu$ 也可能受到污染影响，但其受影响的方式与 $\sigma$ 不完全相同。随机离散异常主要放大残差波动，而连续同方向的块状冲击会改变样本路径的局部水平，从而更直接地干扰长期均值的识别。因此，本文重点比较块状污染下三种方法对 $\mu$ 的估计表现。图 2 报告相应的 RMSE 结果。

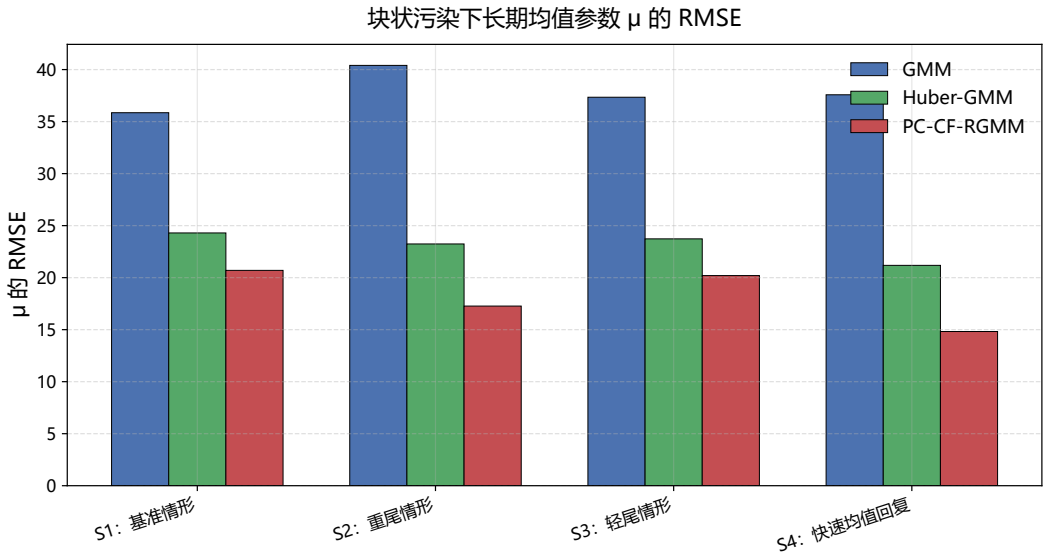



图 2: 块状污染下长期均值参数 $\mu$ 的 RMSE

在四个参数场景中，PC-CF-RGMM 均明显降低了块状污染下 $\mu$ 的 RMSE。具体而言，GMM 的 $\mu$ RMSE 分别为 35.85、40.40、37.34 和 37.58，而 PC-CF-RGMM 分别降至 20.70、17.27、20.20 和 14.82，对应降幅约为 42.3%、57.3%、45.9% 和 60.6%。这一结果也可以从表 5 中的估计均值对照看出：在块状污染下，GMM 的 $\mu$ 估计均值明显高于真实值 20，而 PC-CF-RGMM 的估计均值整体更接近真值。这说明稳健方法的收益并不局限于尺度参数；当异常观测以连续块状形式改变样本路径时，PC-CF-RGMM 也能更好地保护均值回复结构，从而给出更稳定的长期均值估计。

与上一小节结合来看，污染对不同参数的影响具有明显结构差异。随机污染、尾部污染和块状污染首先破坏的是尺度参数识别，因为异常增量会直接进入残差平方类矩条件；而连续块状冲击还会改变样本路径的局部水平，从而进一步影响长期均值识别。PC-CF-RGMM 在 $\sigma$ 和块状污染下的 $\mu$ 这两类关键参数上均表现出更高稳定性，说明其作用不仅是降低单个极端观测对估计方程的影响，也是在污染环境下维持 CTS-OU 模型核心结构参数的可解释性。

## 4.5 模拟结果小结

Monte Carlo 结果表明，稳健化和 PC 正则化的收益主要集中在受污染影响最直接的核心结构参数上。普通 GMM 容易将异常增量吸收到尺度参数 $\sigma$ 中，而 Huber-GMM 和 PC-CF-RGMM 能显著降低这种偏离；在连续块状污染下，PC-CF-RGMM 对长期均值 $\mu$ 的估计也更稳定。与此同时，尾部参数 $\alpha$ 和 $\lambda$ 在有限样本下仍对 CF 频率、污染机制和权重矩阵处理较为敏感。因此，模拟结果应理解为稳健性、有限样本效率和尾部参数识别之间的权衡，而非某一方法在所有参数上的全面支配。

# 5 VIX 波动率指数的稳健 GMM 实证分析

本节将 GMM、Huber-GMM 和 PC-CF-RGMM 应用于 CBOE VIX 日度数据，以检验稳健化动态矩和主成分正则化权重矩阵在真实金融时间序列中的作用。VIX 通常被视为市场预期波动率和风险情绪的重要指标 (Whaley, 2000)，其均值回复、高持续性和危机期尖峰特征也使其成为检验非高斯 OU 型模型的典型金融序列 (Grünbichler and Longstaff, 1996; Mencía and Sentana, 2013)。由于真实样本中不存在可直接比较的真实参数，本文不以单次点估计的“准确性”作为实证评价标准，而是重点考察三类证据：全样本结构参数差异、组合矩条件协方差矩阵病态程度，以及滚动窗口和人工异常冲击下的参数稳定性。一步条件均值预测仅作为补充检验。

考虑到 VIX 水平序列始终为正，且在危机时期可能出现剧烈尖峰，本文以

$$X_t = \log(\mathrm{VIX}_t) \tag{62}$$

作为 OU 状态变量，并估计如下 CTS-OU 模型：

$$dX_t = -\kappa(X_t - \mu)\,dt + \sigma\,dL_t, \tag{63}$$

其中 $L_t$ 为标准化对称 CTS Lévy 过程。需要说明的是，对称 CTS 扰动主要用于刻画跳跃、尖峰厚尾和尾部指数衰减特征，并不直接刻画上下尾不对称。采用非高斯 OU 型结构描述金融波动率动态的思路与 Barndorff-Nielsen and Shephard (2001) 的模型框架一致，而 tempered stable 扰动的尾部削减结构则与 Rosiński (2007) 和 Küchler and Tappe (2013) 的理论设定相呼应。因此，本文实证结果应理解为对稳健 GMM 估计框架的检验，而非对 VIX 条件分布全部特征的完整建模。

## 5.1 VIX 数据特征与 log-CTS-OU 模型设定

本文使用 VIX 日度数据[1]，样本区间为 2019 年 1 月 3 日至 2026 年 5 月 5 日，共包含 1914 个观测值。样本期间覆盖 2020 年疫情冲击、2022 年市场波动上升、2024 年局部波动率跳升以及 2025 年以来的高波动阶段。这一时期异常观测和重尾扰动频繁出现，适合检验稳健估计方法的表现。由于 VIX 与市场压力和预期波动率密切相关，其极端尖峰和均值回复特征也是 VIX 衍生品定价文献关注的核心问题 (Whaley, 2000; Grünbichler and Longstaff, 1996; Mencía and Sentana, 2013)。图 3 给出建模使用的 log(VIX) 序列。

[1]数据来源：CBOE Volatility Index: VIX (VIXCLS)，Federal Reserve Bank of St. Louis，https://fred.stlouisfed.org/series/VIXCLS/。

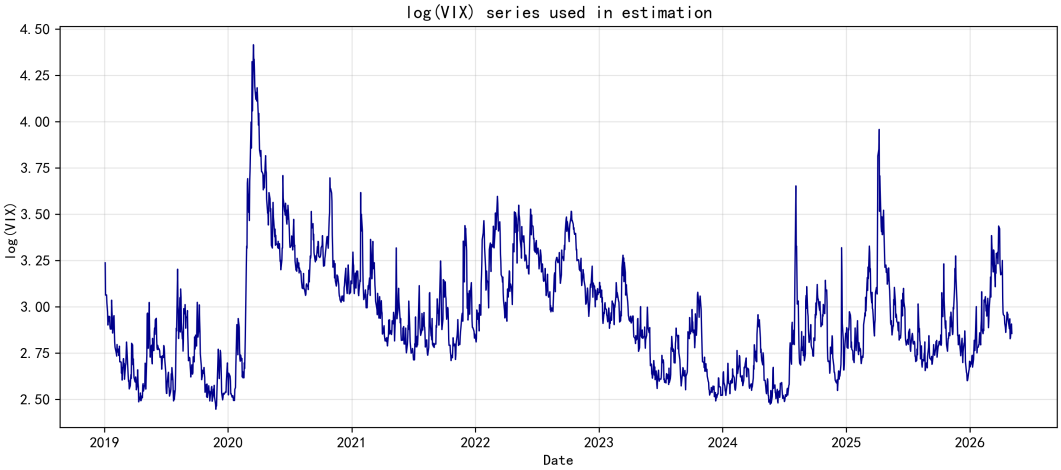



图 3: 建模输入序列：log(VIX)

表 6 报告 log(VIX) 及其一阶差分的主要描述性统计。可以看到，log(VIX) 的一阶自相关系数为 0.9676，说明波动率水平具有较强持续性；$\Delta\log(\text{VIX})$ 的峰度为 9.3655，明显高于正态分布峰度 3，说明日度变化存在显著尖峰厚尾特征。此外，$\Delta\log(\text{VIX})$ 的偏度为 1.0877，表明 VIX 日度变化还存在一定正偏和上下尾不对称。上述事实说明，使用非高斯 Lévy 扰动刻画 VIX 动态具有经验合理性。类似的尖峰厚尾和跳跃特征也广泛存在于资产收益数据中，Carr et al. (2002) 对资产收益精细结构的经验研究为此类非高斯建模提供了重要证据。同时，重尾和异常跳跃也意味着未稳健化动态矩可能受到极端观测显著影响。

表 6: VIX 数据主要描述性统计

| 序列 | $n$ | 均值 | 标准差 | 偏度 | 峰度 | ACF(1) |
|---|---|---|---|---|---|---|
| log(VIX) | 1914 | 2.9513 | 0.3045 | 0.9474 | 4.4094 | 0.9676 |
| $\Delta\log(\text{VIX})$ | 1913 | -0.0002 | 0.0772 | 1.0877 | 9.3655 | -0.0807 |

因此，VIX 样本为本文方法提供了一个实证检验环境：OU 结构用于刻画波动率水平的均值回复和高持续性，CTS 扰动用于刻画非高斯跳跃和厚尾特征，而样本中的极端波动则为比较三种 GMM 方法的结构参数稳定性提供了依据。更多数据诊断图见附录 C.1。

## 5.2 全样本结构参数估计与矩协方差诊断

表 7 报告三种方法在全样本上的参数估计结果。三种方法均成功收敛，但得到的结构参数存在明显差异。

表 7: VIX 全样本结构参数估计结果

| 方法 | $\kappa$ | $\mu$ | $\sigma$ | $\alpha$ | $\lambda$ | 目标函数值 | PC 秩 |
|---|---|---|---|---|---|---|---|
| GMM | 0.015709 | 2.521732 | 0.083722 | 0.959629 | 0.491605 | 0.048162 | – |
| Huber-GMM | 0.023970 | 2.538352 | 0.049531 | 1.750847 | 9.578064 | 0.068582 | – |
| PC-CF-RGMM | 0.029793 | 2.653616 | 0.050892 | 0.276257 | 2.655769 | 0.034647 | 6 |

**参数估计差异。** 从均值回复速度看，PC-CF-RGMM 的 $\widehat{\kappa} = 0.029793$，高于 GMM 的 0.015709 和 Huber-GMM 的 0.023970，说明 PC-CF-RGMM 在全样本中识别出更强的日度均值回复。长期均值方面，三种方法的 $\widehat{\mu}$ 分别为 2.521732、2.538352 和 2.653616，对应的 VIX 长期中枢约为

$$\exp(2.521732) \approx 12.45, \quad \exp(2.538352) \approx 12.66, \quad \exp(2.653616) \approx 14.20.$$

PC-CF-RGMM 给出的长期中枢略高，更接近包含多个高波动阶段后的整体样本水平。

尺度参数方面，GMM 的 $\widehat{\sigma} = 0.083722$，明显高于 Huber-GMM 的 0.049531 和 PC-CF-RGMM 的 0.050892。这与数值模拟中的发现一致：未稳健化 GMM 更容易将极端波动吸收到扰动尺度参数中，而 Huber 有界化和 PC 正则化会降低极端残差对尺度估计的影响。该结果也与稳健 GMM 文献中关于无界矩函数易受异常观测影响的讨论一致 (Ronchetti and Trojani, 2001; Dell'Aquila et al., 2003)。

尾部参数方面，三种方法差异更大。GMM 给出 $\widehat{\alpha} = 0.959629$ 和 $\widehat{\lambda} = 0.491605$，其中 $\alpha$ 接近 CTS 特征指数计算中的数值敏感区域 $\alpha = 1$。Huber-GMM 得到较大的 $\widehat{\alpha} = 1.750847$ 和 $\widehat{\lambda} = 9.578064$，对应较轻尾结构。PC-CF-RGMM 则得到 $\widehat{\alpha} = 0.276257$ 和 $\widehat{\lambda} = 2.655769$，体现出更强的重尾特征。尾部参数在有限样本下对 CF 频率、极端观测和权重矩阵处理较为敏感。因此，本文不将尾部参数的单次点估计视为某种方法绝对优越的证据，而仅将其视为不同矩条件处理方式下尾部结构识别差异的体现。

**矩协方差病态诊断。** 进一步地，表 8 报告组合矩条件协方差矩阵的特征值诊断结果。三种方法的矩条件维数均为 22。可以看到，未加岭（ridge）正则项的原始矩协方差矩阵具有严重病态性。全样本下，GMM 的最小特征值为负的数值误差量级，对应条件数为无穷大；Huber-GMM 和 PC-CF-RGMM 的原始条件数也分别达到 $7.66 \times 10^9$ 和 $2.62 \times 10^{10}$。即使加入 $10^{-4}I$ 的 ridge 项后，条件数仍在 $3.4 \times 10^4$ 至 $2.2 \times 10^5$ 之间。

表 8: 矩条件协方差矩阵诊断

| 样本 | 方法 | 矩条件维数 | 原始条件数 | ridge 后条件数 | $\tau = 0.90$ PC 秩 |
|---|---|---|---|---|---|
| 全样本 | GMM | 22 | $\infty$ | $2.17 \times 10^{5}$ | 3 |
| 全样本 | Huber-GMM | 22 | $7.66 \times 10^{9}$ | $3.59 \times 10^{4}$ | 6 |
| 全样本 | PC-CF-RGMM | 22 | $2.62 \times 10^{10}$ | $3.44 \times 10^{4}$ | 6 |
| 训练样本 | GMM | 22 | $\infty$ | $2.33 \times 10^{5}$ | 3 |
| 训练样本 | Huber-GMM | 22 | $1.33 \times 10^{12}$ | $3.48 \times 10^{4}$ | 6 |
| 训练样本 | PC-CF-RGMM | 22 | $2.88 \times 10^{12}$ | $3.66 \times 10^{4}$ | 6 |

这一结果说明，在 VIX 实证样本中，组合矩条件之间存在强相关和近冗余方向，直接反演权重矩阵可能放大小特征值方向的有限样本噪声。这正是多矩条件 GMM 中正则化方法试图解决的问题，相关讨论可参见 Doran and Schmidt (2006) 和 Carrasco (2012)。PC-CF-RGMM 在全样本中保留 6 个主成分方向，其累计解释比例为 0.9003；在训练样本中同样保留 6 个主成分方向，累计解释比例为 0.9182。图 4 给出全样本 PC-CF-RGMM 下矩协方差矩阵的特征值谱。可以看到，特征值呈现明显下降，较小特征值方向的信息强度显著弱于前几个主方向。因此，PC 正则化在实证中并非单纯的数值技巧，而是针对多矩条件权重矩阵病态的一种必要处理。

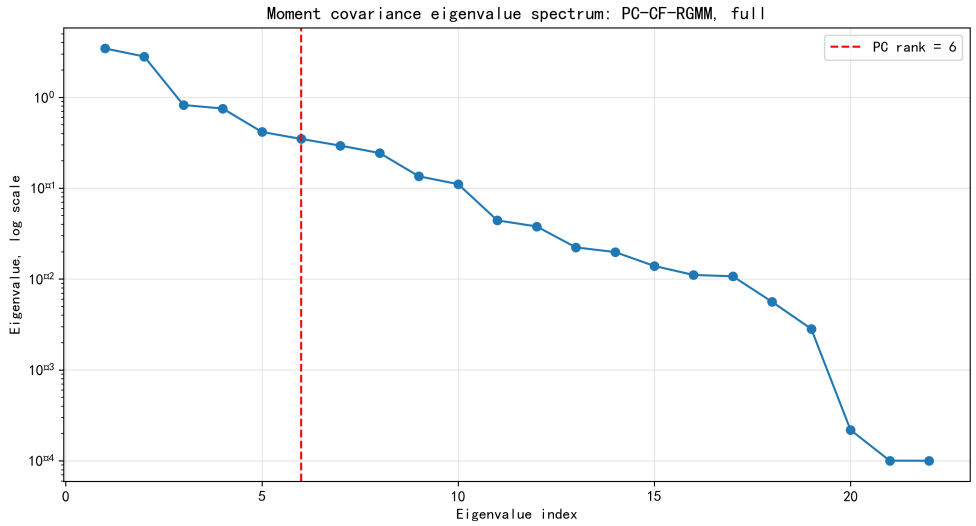



图 4: PC-CF-RGMM 的矩条件协方差矩阵特征值谱

需要强调的是，表 7 中的目标函数值仅作为各方法内部优化诊断量。由于三种方法使用的动态矩变换和权重矩阵不同，目标函数值不宜直接作为跨方法优劣比较依据。更合理的比较重点是参数位置、稳健性表现以及权重矩阵病态处理方式。

## 5.3 滚动窗口下结构参数的时间稳定性

为了考察真实样本中参数估计的时间稳定性，本文进一步进行滚动窗口估计。这里所说的滚动窗口，是指在固定窗口长度下按给定步长向前移动样本区间，并在每个窗

口内重新估计模型参数。与全样本一次性估计相比，这种做法能够更直接地观察参数估计是否会随着局部样本中异常波动的出现而发生明显漂移。本文取窗口长度为 500 个观测、步长为 60 个观测，共得到 24 个窗口。考虑到前文模拟与实证都表明尺度参数 $\sigma$ 对异常观测最为敏感，本文重点报告 $\sigma$ 的滚动窗口结果。表 9 给出三种方法在各窗口下 $\sigma$ 的稳定性摘要。

表 9: 滚动窗口下尺度参数 $\sigma$ 的稳定性

| 方法 | 均值 | 标准差 | 最小值 | 最大值 |
|---|---|---|---|---|
| GMM | 0.080710 | 0.012821 | 0.052019 | 0.096332 |
| Huber-GMM | 0.049901 | **0.005004** | 0.040262 | 0.055962 |
| PC-CF-RGMM | 0.050883 | 0.005109 | 0.042225 | 0.056798 |

表 9 显示，普通 GMM 的 $\sigma$ 在不同窗口之间波动幅度最大，而 Huber-GMM 和 PC-CF-RGMM 的窗口间估计更集中。结合全样本估计结果来看，这意味着一旦局部样本中包含极端波动或短期冲击，未稳健化 GMM 更容易把这些异常变化吸收到扰动尺度参数中，从而导致不同窗口之间的估计值出现明显起伏。相比之下，稳健化动态矩能够抑制极端观测对估计方程的直接冲击，而主成分正则化有助于降低病态权重方向对局部样本变化的放大作用。需要注意的是，在该滚动窗口实验中，Huber-GMM 与 PC-CF-RGMM 的 $\sigma$ 稳定性非常接近，二者均明显优于普通 GMM。因此，滚动窗口结果更适合被理解为稳健化处理整体上提高了尺度参数的时间稳定性，而不是说明某一种稳健方法在所有窗口中都严格占优。$\kappa$、$\mu$、$\sigma$ 的完整滚动估计路径见附录 C.2。

## 5.4 胖手指（fat-finger）异常冲击下的稳健性检验

金融市场中由人工录入失误、交易系统错误或异常下单造成的极端报价，通常被称为胖手指错误（fat-finger error）或“乌龙指”[2]。这类异常在数据中通常表现为单点或短期连续异常增量，并可能通过残差平方项和状态变量交互项影响未稳健化 GMM 的动态矩条件。为检验不同方法对异常观测的敏感性，本文在真实 VIX 样本基础上构造胖手指型人工扰动。

具体地，本文先计算原始 log(VIX) 增量，然后向增量序列中加入幅度为 8 倍日度增量标准差的胖手指型人工冲击，并由扰动后的增量重构新的 log(VIX) 路径。本文考虑五类扰动情形：单日正向冲击、单日负向冲击、1% 随机冲击、10 日连续正向块状冲击和 10 日连续负向块状冲击。其中，单日冲击用于刻画孤立异常报价，随机冲击用于刻画分散出现的数据或交易异常，连续块状冲击则用于刻画短期内连续出现的同方向异常增量。每类扰动重复 10 次，冲击位置随机选择。对每一条扰动后的路径，分别使用 GMM、Huber-GMM 和 PC-CF-RGMM 重新估计模型参数，并与原始样本估计结果进行比较。

[2]关于 fat-finger error 的一般定义，可参见 Wikipedia 词条 *Fat-finger error*，https://en.wikipedia.org/wiki/Fat-finger_error。本文仅借用该概念刻画人为或系统性操作错误导致的异常增量。

表 10 报告不同胖手指型扰动下 $\sigma$ 相对于原始样本估计值的平均相对变化百分比。可以看到，在单日冲击下，三种方法的 $\sigma$ 变化整体较小，方法之间差异也不构成稳定排序；但当扰动扩展为随机多点冲击或连续块状冲击时，普通 GMM 的尺度参数明显更敏感，而 Huber-GMM 和 PC-CF-RGMM 的变化幅度较小。

表 10: 胖手指型异常冲击下 $\sigma$ 的相对变化

| 扰动情形 | GMM | Huber-GMM | PC-CF-RGMM |
|---|---|---|---|
| 单日正向冲击 | **0.54** | 2.09 | 2.26 |
| 单日负向冲击 | 3.02 | **1.26** | 1.60 |
| 1% 随机冲击 | 40.84 | 17.66 | **14.88** |
| 10 日正向块状冲击 | 131.85 | 29.64 | **21.10** |
| 10 日负向块状冲击 | 674.99 | 17.81 | **13.92** |

最明显的差异出现在连续块状冲击下。10 日负向块状冲击中，GMM 的 $\sigma$ 平均相对变化达到 674.99%，而 Huber-GMM 和 PC-CF-RGMM 分别为 17.81% 和 13.92%。10 日正向块状冲击中，GMM 的 $\sigma$ 变化为 131.85%，而 PC-CF-RGMM 为 21.10%。在 1% 随机冲击下，PC-CF-RGMM 的 $\sigma$ 变化也低于 GMM 和 Huber-GMM。上述结果说明，当异常观测不再只是孤立单点，而是以随机多点或连续块状形式进入样本时，未稳健化 GMM 更容易将这些异常变化解释为扰动尺度上升。

图 5 以对数坐标展示了表 10 的结果。使用对数坐标是因为不同扰动情形下 GMM 的相对变化跨度较大，若使用普通线性坐标，小幅变化会被压缩得不易观察。从图中可以看到，随着扰动从单日冲击扩展到随机冲击和连续块状冲击，GMM 的尺度参数敏感性迅速上升，而两种稳健方法的变化相对平缓。

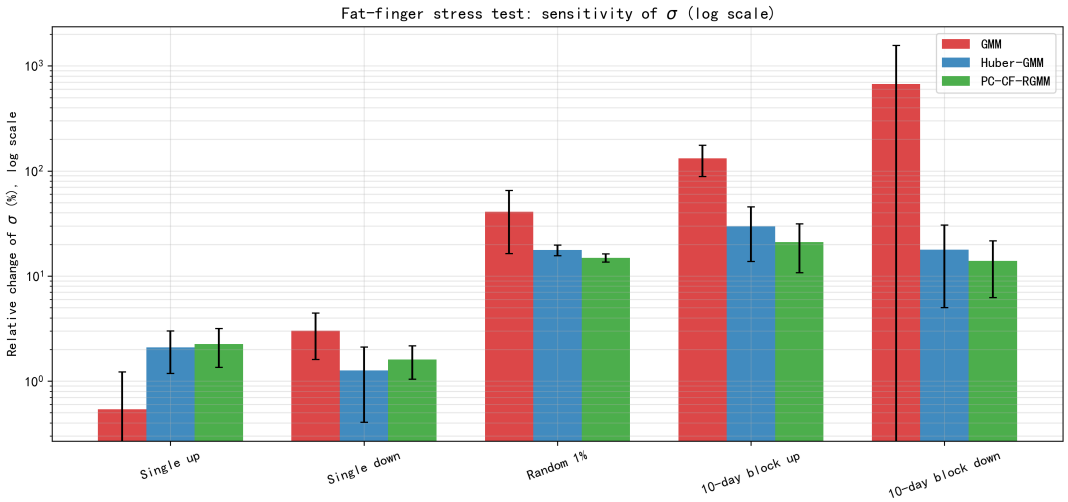



图 5: 胖手指型异常冲击下 $\sigma$ 的敏感性比较

为了进一步考察胖手指型异常冲击对核心结构参数整体的影响，表 11 报告 $(\kappa, \mu, \sigma)$

的相对距离：

$$D_{\kappa,\mu,\sigma} = \left[ \left( \frac{\widehat{\kappa}_{\text{new}} - \widehat{\kappa}_{\text{base}}}{\widehat{\kappa}_{\text{base}}} \right)^2 + \left( \frac{\widehat{\mu}_{\text{new}} - \widehat{\mu}_{\text{base}}}{\widehat{\mu}_{\text{base}}} \right)^2 + \left( \frac{\widehat{\sigma}_{\text{new}} - \widehat{\sigma}_{\text{base}}}{\widehat{\sigma}_{\text{base}}} \right)^2 \right]^{1/2}. \tag{64}$$

其中，$\widehat{\theta}_{\text{base}}$ 表示原始样本估计值，$\widehat{\theta}_{\text{new}}$ 表示扰动样本重新估计得到的参数值。该指标越大，说明扰动后核心结构参数相对于原始估计结果的偏移越明显。

表 11: 胖手指型异常冲击下核心结构参数距离 $D_{\kappa,\mu,\sigma}$

| 扰动情形 | GMM | Huber-GMM | PC-CF-RGMM |
|---|---|---|---|
| 单日正向冲击 | **0.161** | 0.315 | 0.364 |
| 单日负向冲击 | **0.154** | 0.255 | 0.338 |
| 1% 随机冲击 | 0.816 | **0.783** | 0.842 |
| 10 日正向块状冲击 | 1.962 | 1.337 | **1.295** |
| 10 日负向块状冲击 | 8.627 | **1.073** | 1.098 |

表 11 显示，在单日冲击下，GMM 的核心参数距离反而较小。这说明在非常局部、影响有限的扰动下，稳健化处理并不必然带来更小的参数变化，这与稳健性和有限样本效率之间的权衡是一致的。但在连续块状冲击下，GMM 的参数距离显著放大。尤其是在 10 日负向块状冲击下，GMM 的 $D_{\kappa,\mu,\sigma}$ 达到 8.627，而 Huber-GMM 和 PC-CF-RGMM 分别为 1.073 和 1.098。也就是说，当异常观测连续出现并改变样本路径的局部水平时，未稳健化 GMM 的均值回复结构和尺度参数都会受到明显扰动，而稳健方法能够更好地保持核心结构参数稳定。

综合滚动窗口和胖手指型异常冲击实验可以看到，稳健方法的优势主要体现在复杂异常环境下，而不是在每一个轻微扰动下都取得最小变化。对于单日冲击，三种方法的表现差异有限；对于随机多点冲击和连续块状冲击，PC-CF-RGMM 在 $\sigma$ 敏感性上表现最稳定，Huber-GMM 和 PC-CF-RGMM 在核心结构参数距离上也明显低于 GMM。这与第 4 节 Monte Carlo 结果形成一致证据，说明在真实 VIX 样本中，动态矩稳健化和权重矩阵正则化确实有助于降低胖手指型异常观测对结构参数估计的影响。这一发现也与稳健统计中通过有界估计函数控制异常观测影响的基本思想一致 (Huber and Ronchetti, 2009; Ronchetti and Trojani, 2001)。

## 5.5 一步均值预测的补充检验

前文的全样本估计、矩协方差诊断、滚动窗口和胖手指型异常冲击检验，主要从结构参数稳定性角度评价三种估计方法。由于本文方法的目标是稳健识别 CTS-OU 模型的结构参数，而不是专门最小化短期预测误差，本文进一步报告一步条件均值预测结果，作为补充性检验。

样本按时间顺序划分为训练集和测试集，其中后 20% 作为测试集。对每种方法，

先在训练集上重新估计参数，然后使用 OU 模型的一步条件均值

$$\widehat{X}_{t+1} = \widehat{\mu} + e^{-\widehat{\kappa}h}(X_t - \widehat{\mu}) \tag{65}$$

进行预测。预测误差定义为

$$e_{t+1} = X_{t+1} - \widehat{X}_{t+1}. \tag{66}$$

表 12 报告样本外一步均值预测误差。可以看到，三种方法的一步预测误差非常接近。Huber-GMM 的 RMSE 为 0.085684，略低于 GMM 的 0.085878 和 PC-CF-RGMM 的 0.085866，但差异极小；MAE 也呈现类似结果。

表 12: 样本外一步均值预测误差

| 方法 | 训练目标函数值 | MAE | RMSE | 平均误差 | 误差标准差 |
|---|---|---|---|---|---|
| GMM | 0.049481 | 0.057579 | 0.085878 | 0.006546 | 0.085740 |
| Huber-GMM | 0.070428 | 0.057102 | 0.085684 | 0.009623 | 0.085253 |
| PC-CF-RGMM | 0.036663 | 0.057437 | 0.085866 | 0.008199 | 0.085586 |

这一结果说明，对于高持续性的 log(VIX) 序列，一步条件均值预测高度依赖当前状态 $X_t$。均值回复结构在波动率和 VIX 建模中具有长期应用基础 (Grünbichler and Longstaff, 1996; Mencía and Sentana, 2013)，但本文结果表明，结构参数稳健性与短期条件均值预测精度并不必然等价。即使三种方法得到的结构参数存在差异，这些差异也未必会转化为显著不同的一步均值预测误差。换言之，本文的实证证据并不支持将 PC-CF-RGMM 的优势解释为短期均值预测能力的提升。相反，结合前文滚动窗口和异常冲击实验可以看出，PC-CF-RGMM 的主要价值在于重尾、异常观测和矩条件病态并存时更稳定地识别结构参数，尤其是尺度参数 $\sigma$。

### 5.6 实证结果小结

VIX 实证结果与 Monte Carlo 模拟形成了一致证据。全样本估计显示，普通 GMM 给出的尺度参数 $\sigma$ 明显高于两种稳健方法；矩条件协方差诊断表明，组合矩条件存在明显病态性，因而 PC 正则化具有实际必要性。滚动窗口和胖手指型异常冲击实验进一步说明，在随机多点冲击和连续块状冲击下，稳健方法能够更好地保持结构参数稳定。一步均值预测结果则显示，三种方法的样本外预测误差非常接近，说明本文方法的优势主要不在于短期均值预测，而在于重尾、异常观测和矩条件病态并存时的结构参数稳健识别。

## 6 结论

本文研究 CTS Lévy 过程驱动 OU 模型在重尾和异常观测环境下的稳健 GMM 估计问题。CTS-OU 模型能够同时刻画均值回复、跳跃、厚尾和尾部指数衰减特征，但

其转移密度通常难以写成简单闭式形式，使得似然估计在实际应用中较为困难。为此，本文在统一包含标准化特征函数矩的框架下比较基准 GMM、Huber-GMM 和 PC-CF-RGMM。其中，Huber-GMM 通过有界化低阶动态矩减弱极端观测影响，PC-CF-RGMM 则进一步通过主成分正则化缓解多矩条件下权重矩阵病态问题。

Monte Carlo 模拟和 VIX 实证结果表明，稳健化处理的收益主要体现在受异常观测影响最直接的核心结构参数上。普通 GMM 容易将随机污染、尾部污染和块状污染解释为扰动尺度 $\sigma$ 的上升，而 Huber-GMM 和 PC-CF-RGMM 能显著降低这种偏离；在连续块状污染下，PC-CF-RGMM 对长期均值 $\mu$ 的估计也更稳定。VIX 实证进一步显示，真实样本中的组合矩条件协方差矩阵存在明显病态性，滚动窗口和胖手指型异常冲击实验也支持稳健方法在复杂异常环境下具有更强的结构参数稳定性。

同时，本文并不将 PC-CF-RGMM 解释为在所有参数和所有场景下都占优的方法。尾部参数 $\alpha$ 和 $\lambda$ 在有限样本下仍对 CF 频率选择、污染机制和权重矩阵处理较为敏感；样本外一步条件均值预测结果也显示，三种方法的预测误差非常接近。因此，本文方法的主要价值不在于机械地降低短期预测 RMSE，而在于当样本中存在重尾、异常跳跃和多矩条件病态时，仍能给出更稳定、更可解释的结构参数估计。

后续研究可以从以下方向拓展：第一，考虑非对称 tempered stable 过程，以刻画 VIX 增量中的上下尾不对称；第二，研究数据驱动的 CF 频率选择和矩条件筛选方法；第三，将 PC-CF-RGMM 推广至多维 Lévy 驱动 OU 模型、随机波动率模型或带时变中心趋势的 VIX 模型；第四，结合密度预测、VaR 回测和 Expected Shortfall 回测等指标，进一步评估稳健特征函数矩估计在尾部风险管理中的作用。

# A CTS-OU 随机积分项的数值抽样方法

本文在 Monte Carlo 实验中并不直接模拟连续时间 CTS Lévy 路径，而是直接模拟离散时间 OU 的随机积分项 $\eta_j$。对给定参数 $\theta = (\kappa, \mu, \sigma, \alpha, \lambda)'$，首先根据

$$\phi_h(u;\theta) = \exp\left\{ \int_0^h \Psi_L\big(u\sigma e^{-\kappa r}; \alpha, \lambda\big)\, dr \right\}$$

计算 OU 随机积分项的特征函数，其中积分项通过数值求积计算。随后，利用 Gil–Pelaez 反演公式 (Gil-Pelaez, 1951) 将特征函数反演为分布函数：

$$F_\eta(x) = \frac{1}{2} - \frac{1}{\pi} \int_0^\infty \mathrm{Im}\left\{ \frac{e^{-iux}\phi_h(u;\theta)}{u} \right\} du.$$

在数值实现中，上述积分在有限区间上截断，并在预设的 $x$ 网格上计算近似分布函数 $\widehat{F}_\eta(x)$；随后对其进行单调化处理并构造数值反函数 $\widehat{F}_\eta^{-1}(\cdot)$。给定独立均匀随机数 $U_j \sim U(0,1)$，令

$$\eta_j = \widehat{F}_\eta^{-1}(U_j),$$

即可得到 OU 随机积分项的模拟值。最后，依据离散递推式生成无污染样本路径。对每一组参数场景，本文预先构造相应的创新项数值抽样器，并在重复模拟中复用该抽样器。

# B Monte Carlo 补充结果与数值优化诊断

本附录报告 Monte Carlo 实验的补充结果，包括创新项数值抽样方法、重点参数的 Bias、MAE、估计标准差以及数值优化表现。所有统计量均基于成功收敛且未被判定为边界解的重复实验计算。与正文一致，附录重点补充长期均值参数 $\mu$ 和尺度参数 $\sigma$ 的结果；尾部参数相关结果仅作为完整性补充。

## B.1 重点参数的补充统计量

表 13 和表 14 分别报告长期均值参数 $\mu$ 与尺度参数 $\sigma$ 的 Bias、MAE 和估计标准差。表中各单元格按照

$$\text{Bias/MAE/SD}$$

的顺序给出。

从表 13 可以看到，块状污染对长期均值参数 $\mu$ 的影响明显强于随机污染和尾部污染。这与正文中的解释一致：连续同方向异常增量会改变样本路径的局部水平，从而更直接地干扰长期均值的识别。在多数块状污染场景下，Huber-GMM 和 PC-CF-RGMM 均能降低 $\mu$ 的 MAE 和估计波动，其中 PC-CF-RGMM 的改善通常更为明显。

从表 14 可以看到，尺度参数 $\sigma$ 是三种方法差异最稳定、最清楚的比较对象。无论在随机污染、块状污染还是尾部污染下，未稳健化 GMM 的 Bias 和 MAE 往往显著上升，而 Huber-GMM 与 PC-CF-RGMM 的误差明显较小。这与正文关于 $\sigma$ 的 RMSE 结果相一致，进一步说明原始动态矩容易将异常增量解释为真实尺度上升，而稳健化动态矩及主成分正则化有助于抑制这种放大效应。

表 13: 长期均值参数 $\mu$ 的 Bias、MAE 和估计标准差

| 场景 | 污染 | GMM | Huber-GMM | PC-CF-RGMM |
|---|---|---|---|---|
| $S_1$ | $C_0$ | 0.048/0.578/0.745 | 0.037/0.533/0.682 | -0.013/0.524/0.680 |
| $S_1$ | $C_1$ | 2.502/10.588/12.624 | 2.592/9.827/11.645 | 2.290/10.170/12.135 |
| $S_1$ | $C_2$ | 1.678/14.878/18.170 | 0.990/13.827/16.750 | 1.678/14.066/17.499 |
| $S_1$ | $C_3$ | 11.736/29.726/34.050 | 6.711/15.425/23.487 | 3.932/**11.872**/20.436 |
| $S_1$ | $C_4$ | 1.614/14.123/17.694 | 1.309/13.009/16.529 | 0.576/12.418/15.936 |
| $S_2$ | $C_0$ | -0.022/0.615/0.852 | 0.030/0.414/0.507 | 0.039/0.412/0.515 |
| $S_2$ | $C_1$ | 3.139/11.677/13.649 | 3.147/11.265/13.011 | 2.560/11.349/13.277 |
| $S_2$ | $C_2$ | 7.030/17.818/21.422 | 6.497/17.136/20.527 | 6.799/17.176/21.227 |
| $S_2$ | $C_3$ | 20.637/33.999/34.911 | 8.437/13.018/21.775 | 3.917/**8.505**/16.910 |
| $S_2$ | $C_4$ | 3.052/14.870/18.027 | 3.038/14.052/17.264 | 3.385/13.791/17.012 |
| $S_3$ | $C_0$ | 0.038/0.566/0.761 | 0.079/0.471/0.586 | 0.064/0.471/0.597 |
| $S_3$ | $C_1$ | 1.316/10.712/12.951 | 1.264/9.634/11.866 | 0.707/9.894/12.142 |
| $S_3$ | $C_2$ | 5.104/16.828/20.609 | 5.201/16.191/20.135 | 5.268/16.404/20.313 |
| $S_3$ | $C_3$ | 16.622/30.648/33.607 | 6.328/14.007/22.999 | 5.753/**11.072**/19.472 |
| $S_3$ | $C_4$ | 2.448/14.472/17.602 | 1.991/13.652/16.405 | 1.874/13.806/17.094 |
| $S_4$ | $C_0$ | 0.042/0.191/0.276 | 0.004/0.179/0.222 | 0.005/0.173/0.221 |
| $S_4$ | $C_1$ | 1.837/11.432/14.133 | 1.790/11.037/13.626 | 1.351/10.657/13.139 |
| $S_4$ | $C_2$ | 1.673/13.890/17.396 | 1.882/13.562/17.013 | 1.185/13.498/16.729 |
| $S_4$ | $C_3$ | 15.549/30.980/34.382 | 5.130/11.764/20.658 | 0.846/**7.706**/14.879 |
| $S_4$ | $C_4$ | 5.635/15.205/17.640 | 5.572/14.464/17.099 | 6.076/14.931/17.300 |

## B.2 数值优化表现

表 15 报告所有模拟设计下三种估计方法的平均数值优化表现，包括原始成功率、有效成功率、失败率、边界解比例与平均运行时间。这里的有效成功率是在原始收敛基础上进一步剔除被判定为边界解的重复实验后得到的比例。

结果显示，GMM 的平均运行时间最低，Huber-GMM 次之，PC-CF-RGMM 由于需要计算组合矩条件协方差矩阵、进行特征值分解并实施二步优化，因此计算成本最高。这说明 PC-CF-RGMM 的稳健性提升并非无代价，而是以更高的计算开销换取污染样本下更稳定的结构参数估计。

本文将距离参数区间边界小于区间长度 1% 的估计记为边界解，并从有效估计样本中剔除。在该判定规则下，表 15 中报告的边界解比例总体较低。不过，这并不意味着所有污染场景下的优化都同样稳定。部分场景中，虽然估计值未触发 1% 的边界判定阈值，但仍可能表现出明显的边界吸引现象，例如块状污染下 GMM 的尺度参数 $\sigma$

表 14: 尺度参数 $\sigma$ 的 Bias、MAE 和估计标准差

| 场景 | 污染 | GMM | Huber-GMM | PC-CF-RGMM |
|---|---|---|---|---|
| $S_1$ | $C_0$ | 0.004/0.021/0.027 | -0.164/0.164/0.027 | -0.157/0.157/0.025 |
| $S_1$ | $C_1$ | 0.316/0.316/0.084 | -0.153/0.153/0.032 | -0.151/0.151/0.028 |
| $S_1$ | $C_2$ | 1.112/1.112/0.845 | -0.079/0.108/0.086 | -0.091/**0.108**/0.067 |
| $S_1$ | $C_3$ | 3.869/3.869/0.004 | 0.818/0.981/1.227 | 0.652/**0.795**/1.111 |
| $S_1$ | $C_4$ | 1.163/1.163/0.132 | -0.141/0.142/0.048 | -0.147/**0.147**/0.032 |
| $S_2$ | $C_0$ | -0.004/0.034/0.042 | -0.367/0.367/0.024 | -0.344/0.344/0.024 |
| $S_2$ | $C_1$ | 0.350/0.350/0.120 | -0.329/0.329/0.035 | -0.310/0.310/0.032 |
| $S_2$ | $C_2$ | 0.880/0.880/0.206 | -0.244/0.244/0.065 | -0.242/0.242/0.043 |
| $S_2$ | $C_3$ | 3.869/3.869/0.004 | 0.608/0.936/1.328 | 0.308/0.614/1.039 |
| $S_2$ | $C_4$ | 1.247/1.247/0.349 | -0.293/0.303/0.108 | -0.295/0.295/0.068 |
| $S_3$ | $C_0$ | 0.007/0.020/0.024 | -0.124/0.124/0.026 | -0.119/0.119/0.025 |
| $S_3$ | $C_1$ | 0.336/0.336/0.099 | -0.113/0.113/0.026 | -0.114/0.114/0.023 |
| $S_3$ | $C_2$ | 0.937/0.937/0.438 | -0.057/0.073/0.058 | -0.071/0.076/0.040 |
| $S_3$ | $C_3$ | 3.869/3.869/0.004 | 0.776/0.934/1.229 | 0.484/0.682/1.043 |
| $S_3$ | $C_4$ | 1.164/1.164/0.178 | -0.092/0.096/0.047 | -0.104/0.105/0.035 |
| $S_4$ | $C_0$ | 0.001/0.024/0.031 | -0.171/0.171/0.025 | -0.164/0.164/0.024 |
| $S_4$ | $C_1$ | 0.302/0.302/0.087 | -0.165/0.165/0.029 | -0.163/0.163/0.026 |
| $S_4$ | $C_2$ | 0.916/0.916/0.690 | -0.110/0.127/0.080 | -0.117/0.128/0.064 |
| $S_4$ | $C_3$ | 3.869/3.869/0.005 | 0.349/0.636/0.974 | 0.425/0.612/1.144 |
| $S_4$ | $C_4$ | 1.102/1.102/0.156 | -0.166/0.166/0.045 | -0.169/0.169/0.037 |

可能靠近上界。此类现象在本文中被理解为约束附近估计不稳定的表现，也与正文关于普通 GMM 容易放大异常观测影响的结论一致。

总体来看，附录中的数值优化结果与正文结论一致：PC-CF-RGMM 在计算成本上高于 GMM 和 Huber-GMM，但在重尾、异常观测和矩条件病态并存的情形下，能够提供更稳健、更加受约束的估计结果。

表 15: 数值优化成功率、边界解比例与平均运行时间

| 方法 | 原始成功率 | 有效成功率 | 失败率 | 边界解比例 | 平均运行时间 |
|---|---|---|---|---|---|
| GMM | 0.999 | 0.999 | 0.001 | 0.000 | 12.5 |
| Huber-GMM | 0.936 | 0.936 | 0.064 | 0.000 | 28.6 |
| PC-CF-RGMM | 0.920 | 0.920 | 0.080 | 0.000 | 55.6 |

# C VIX 数据诊断与参数稳定性补充图

本附录补充正文第 5 节所使用的 VIX 数据诊断图和参数稳定性图形。与正文分析一致，附录图形主要服务于两个目的：第一，说明 log(VIX) 及其增量具有高持续性、尖峰厚尾等经验特征，从而为 CTS-OU 建模和稳健估计提供动机；第二，补充展示不同估计方法下核心结构参数在时间维度上的稳定性差异。

## C.1 VIX 数据诊断图

图 6 给出 VIX 水平序列。与正文中的 log(VIX) 序列相比，原始 VIX 水平序列在危机时期的尖峰更加明显，进一步说明波动率指数存在显著的极端波动阶段。

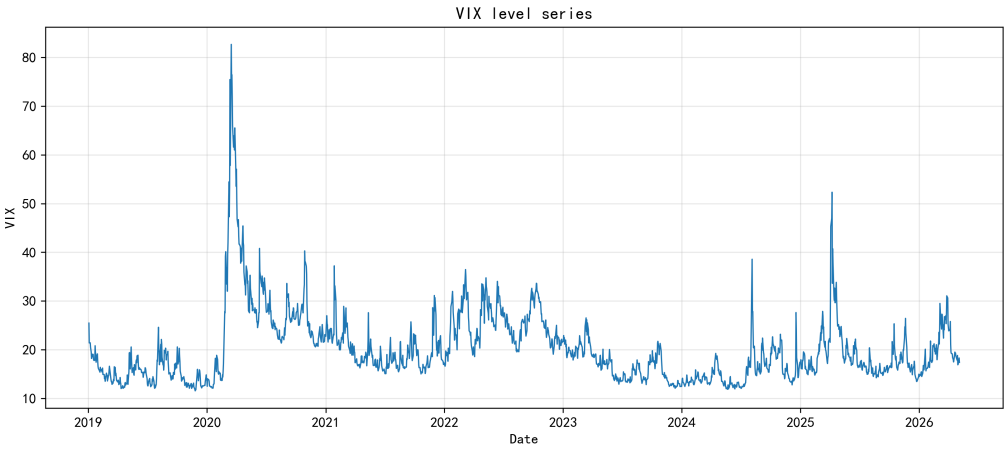



图 6: VIX 水平序列

图 7 和图 8 分别展示 log(VIX) 的分布图与 $\Delta\log(\text{VIX})$ 的正态 QQ 图。可以看到，log(VIX) 的分布相对集中但仍偏离正态，而 $\Delta\log(\text{VIX})$ 的 QQ 图在两端显著偏离正态参考线，说明日度变化具有明显的尖峰厚尾特征。这些事实与正文表 6 的描述性统计结论一致，支持使用非高斯 Lévy 扰动刻画 VIX 的日度动态。

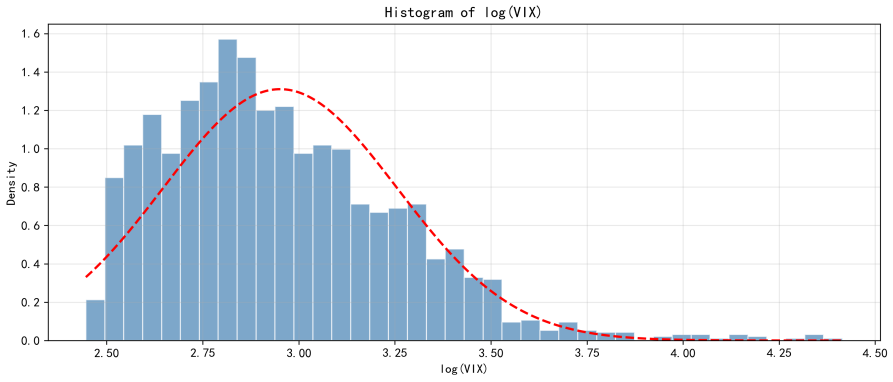



图 7: log(VIX) 的直方图

图 9 和图 10 给出 log(VIX) 及其差分的自相关函数。可以看到，log(VIX) 的自相关衰减较慢，体现出明显的高持续性；相比之下，差分序列的自相关显著减弱。该结果说明，OU 型动态结构对描述波动率水平序列具有经验合理性。

## C.2 滚动窗口核心参数估计路径

为补充正文表 9 的滚动窗口稳定性结果，图 11、图 12 和图 13 分别给出尺度参数 $\sigma$、均值回复速度 $\kappa$ 以及长期均值 $\mu$ 的滚动窗口估计路径。统计量和图形均基于成功

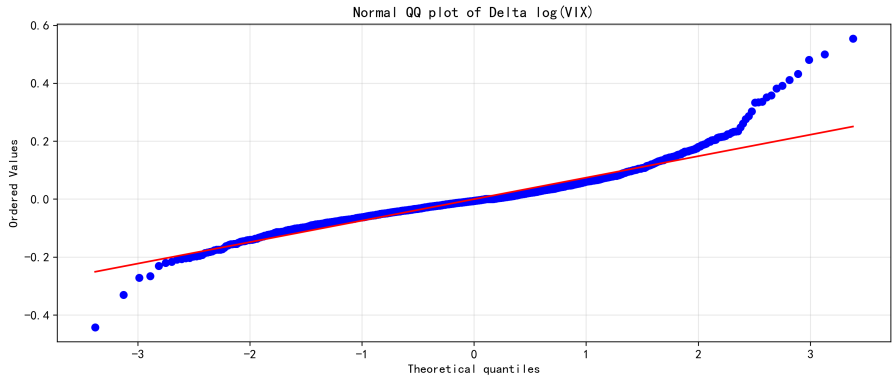



图 8: $\Delta \log(\mathrm{VIX})$ 的正态 QQ 图

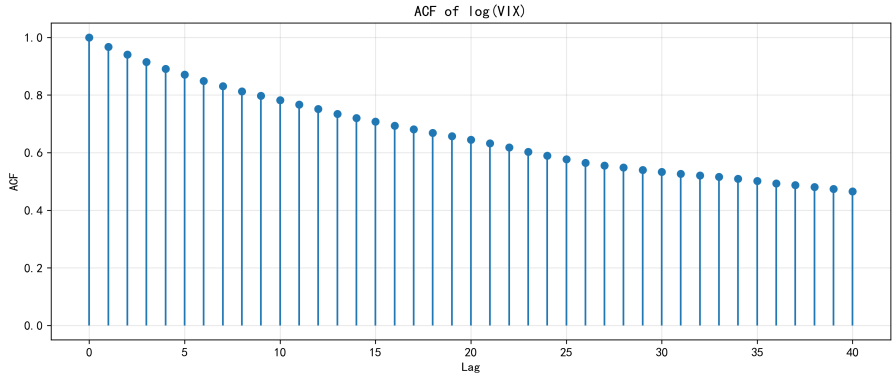



图 9: $\log(\mathrm{VIX})$ 的自相关函数

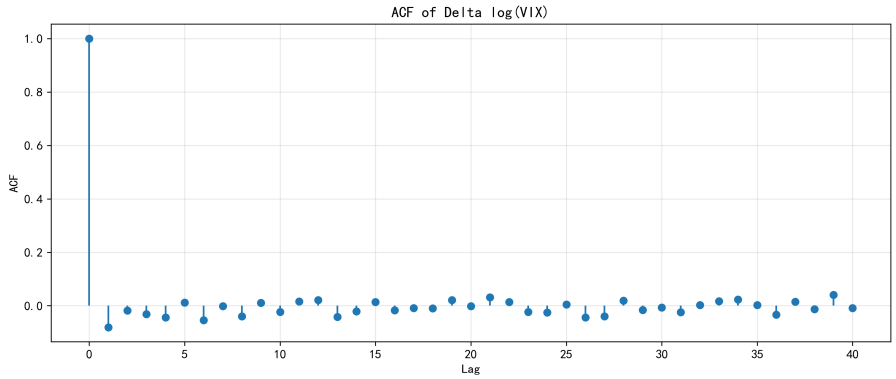



图 10: $\Delta \log(\mathrm{VIX})$ 的自相关函数

收敛的滚动窗口估计结果。

从图 11 可以看到，不同方法在尺度参数 $\sigma$ 上表现出最清楚的稳定性差异。GMM 的 $\sigma$ 路径整体明显高于 Huber-GMM 和 PC-CF-RGMM，并且在不同窗口之间波动更大。相比之下，两种稳健方法的 $\sigma$ 路径更集中，说明 Huber 型动态矩有界化和主成分正则化能够降低极端观测对尺度参数识别的持续影响。

图 12 进一步报告均值回复速度 $\kappa$ 的滚动估计路径。可以看到，三种方法在该参数上的差异也具有一定时间变化特征，但其稳健性差异不如 $\sigma$ 明显。图 13 则给出长期均值 $\mu$ 的滚动窗口估计结果。总体来看，$\mu$ 的估计路径在样本滚动过程中呈现出一定的阶段性变化，但稳健方法得到的轨迹通常更平滑、更集中，说明其对异常样本阶段的敏感度较低。

因此，本文不将滚动窗口结果解释为 PC-CF-RGMM 在所有参数上均无条件占优，而是将其理解为：在真实金融时间序列中，稳健估计在尺度参数识别和核心结构参数稳定性方面提供了更可靠的补充证据。

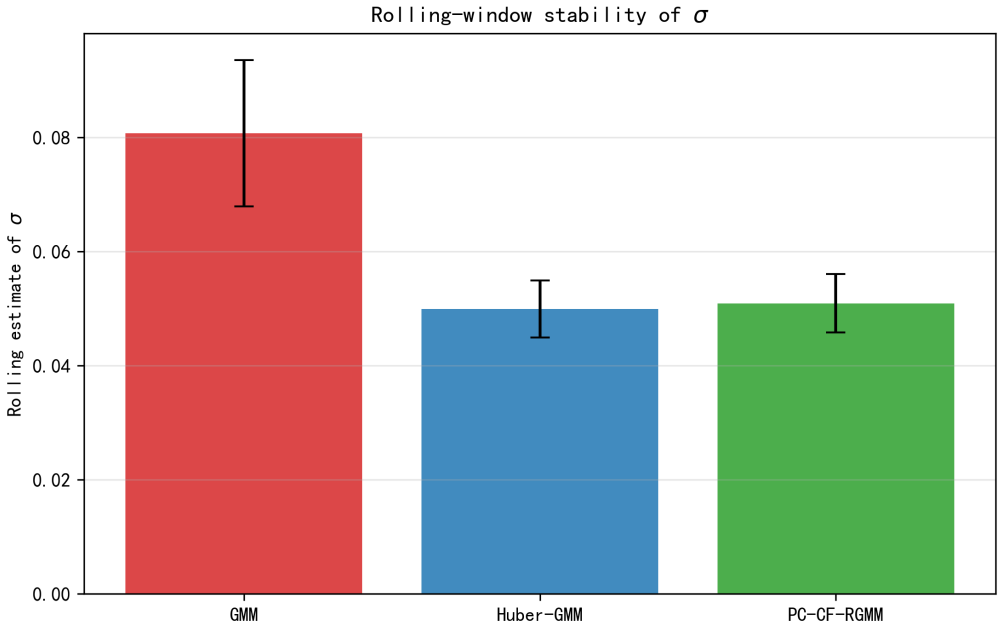



图 11: 滚动窗口估计的尺度参数 $\sigma$

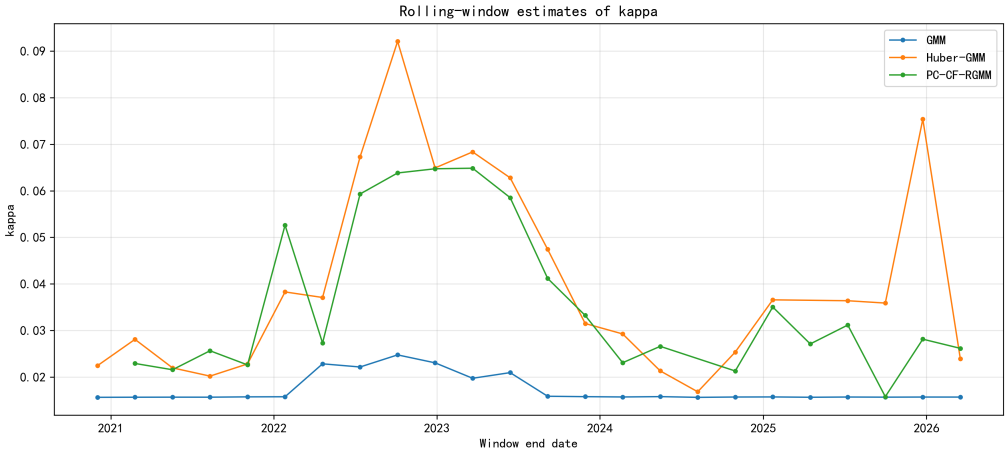



图 12: 滚动窗口估计的均值回复速度 $\kappa$

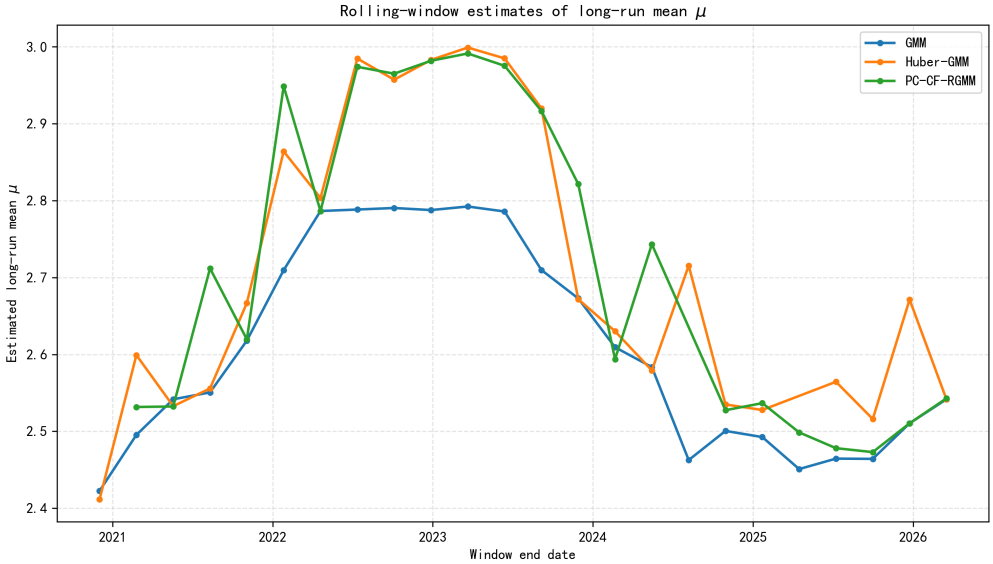



图 13: 滚动窗口估计的长期均值 $\mu$

# 参考文献

Abi Jaber, E., Illand, C., and Li, S. X. (2023). The quintic Ornstein–Uhlenbeck volatility model that jointly calibrates SPX and VIX smiles. *arXiv preprint arXiv:2212.10917*.

Barndorff-Nielsen, O. E. and Shephard, N. (2001). Non-gaussian Ornstein–Uhlenbeck-based models and some of their uses in financial economics. *Journal of the Royal Statistical Society: Series B*, 63(2):167–241.

Carr, P., Geman, H., Madan, D. B., and Yor, M. (2002). The fine structure of asset returns: An empirical investigation. *Journal of Business*, 75(2):305–332.

Carrasco, M. (2012). A regularization approach to the many instruments problem. *Journal of Econometrics*, 170(2):383–398.

Carrasco, M., Chernov, M., Florens, J.-P., and Ghysels, E. (2007). Efficient estimation of general dynamic models with a continuum of moment conditions. *Journal of Econometrics*, 140(2):529–573.

Carrasco, M. and Florens, J.-P. (2000). Generalization of GMM to a continuum of moment conditions. *Econometric Theory*, 16(6):797–834.

Dell'Aquila, R., Ronchetti, E., and Trojani, F. (2003). Robust GMM analysis of models for the short rate process. *Journal of Empirical Finance*, 10(3):373–397.

Doran, H. E. and Schmidt, P. (2006). GMM estimators with improved finite sample properties using principal components of the weighting matrix, with an application to the dynamic panel data model. *Journal of Econometrics*, 133(1):387–409.

Feuerverger, A. and McDunnough, P. (1981). On the efficiency of empirical characteristic function procedures. *Journal of the Royal Statistical Society: Series B*, 43(1):20–27.

Gil-Pelaez, J. (1951). Note on the inversion theorem. *Biometrika*, 38(3–4):481–482.

Grabchak, M. and Sabino, P. (2020). Exact simulation of tempered stable Ornstein–Uhlenbeck processes. *Methodology and Computing in Applied Probability*, 22(2):549–569.

Grünbichler, A. and Longstaff, F. A. (1996). Valuing futures and options on volatility. *Journal of Banking & Finance*, 20(6):985–1001.

Hansen, L. P. (1982). Large sample properties of generalized method of moments estimators. *Econometrica*, 50(4):1029–1054.

Huber, P. J. and Ronchetti, E. M. (2009). *Robust Statistics*. Wiley, Hoboken, NJ, 2 edition.

Kawai, R. and Masuda, H. (2012). On simulation of tempered stable random variates. *Journal of Computational and Applied Mathematics*, 236(8):1953–1973.

Kim, Y. S., Rho, K.-H., and Douady, R. (2022). Tempered stable processes with time-varying exponential tails. *Quantitative Finance*, 22(6):1031–1047.

Knight, J. L. and Yu, J. (2002). Empirical characteristic function in time series estimation. *Econometric Theory*, 18(3):691–721.

Küchler, U. and Tappe, S. (2013). Tempered stable distributions and processes. *Stochastic Processes and their Applications*, 123(12):4256–4293.

Mencía, J. and Sentana, E. (2013). Valuation of VIX derivatives. *Journal of Financial Economics*, 108(2):367–391.

Ronchetti, E. and Trojani, F. (2001). Robust inference with GMM estimators. *Journal of Econometrics*, 101(1):37–69.

Rosiński, J. (2007). Tempering stable processes. *Stochastic Processes and their Applications*, 117(6):677–707.

Whaley, R. E. (2000). The investor fear gauge. *Journal of Portfolio Management*, 26(3):12–17.

Yin, Y. and Huo, W. (2022). An Ornstein–Uhlenbeck model with the stochastic volatility process and tempered stable process for VIX option pricing. *Mathematical Problems in Engineering*, 2022:4018292.